

Wprowadzenie do symulacji i metod Monte Carlo

Projekt 2

Zuzanna Brzóška, anonymous second person

22 maja 2023

Spis treści

1	Wprowadzenie	2
2	Crude Monte Carlo Estimator	2
3	Stratified Estimator	5
3.1	opcja Europejska	5
3.2	opcja Azjatycka	7
4	Antithetic Estimator	10
5	Control Variate Estimator	12

1 Wprowadzenie

Celem niniejszego projektu jest oszacowanie opcji kupna o cenie wyrażonej poprzez

$$I = e^{-r} \mathbb{E}((A_n - K)_+), \quad (1)$$

gdzie

$$A_n = \frac{1}{n} \sum_{i=1}^n S\left(\frac{i}{n}\right),$$

a $S(t)$ jest geometrycznym ruchem Browna $GBM(\mu, \sigma)$ opisanym wzorem

$$S(t) = S(0) \exp\left(\left(r - \frac{\sigma^2}{2}\right)t + \sigma B(t)\right), \quad 0 \leq t \leq T.$$

Tutaj $B(t)$ ($0 \leq t \leq T$) stanowi ruch Browna.

Jeżeli $n = 1$ to (1) nazywamy Europejską opcją kupna, a w przeciwnym przypadku - Azjatycką opcją kupna.

Dla Europejskiej opcji kupna istnieje wzór, zwany formułą Blacka-Scholesa, pozwalający obliczyć dokładną jej wartość:

$$I = e^{-r} \mathbb{E}((S(1) - K)_+) = \mathbb{E}(S(0)\Phi(d_1) - Ke^{-r}\Phi(d_2)),$$

gdzie

$$d_1 = \frac{1}{\sigma} \left[\log \frac{S(0)}{K} + r + \frac{\sigma^2}{2} \right], \quad d_2 = d_1 - \sigma$$

oraz Φ jest dystrybucją standardowego rozkładu normalnego.

Dla branych w projekcie wartości parametrów, czyli: $r = 0.05$, $\sigma = 0.25$, $S(1) = 100$ i $K = 100$, I obliczone za pomocą Blacka-Scholesa wynosi około 12.336.

2 Crude Monte Carlo Estimator

Weźmy $Y = k(V)$, gdzie V ma rozkład jednostajny na B (w tym projekcie $B = [0, 1]$). Wówczas $\mathbb{E}[Y] = I$. Ponadto, niech V_1, \dots, V_R stanowią niezależne kopie V o rozkładzie jednostajnym $\mathcal{U}(B)$. Wtedy estymator

$$\hat{Y}_R^{CMC} = \frac{1}{R} \sum_{j=1}^R Y_j = \frac{1}{R} \sum_{j=1}^R k(V_j)$$

nazywany jest estymatorem Crude Monte Carlo.

W naszym przypadku $k(V) = e^{-r}(A_n - K)_+$. Musimy zatem wygenerować R razy zmienne $B(t)$ z ruchu Browna w punktach $t = 1/n, \dots, 1$.

Dla opcji europejskiej (czyli $n = 1$) musimy więc wygenerować R razy wartość ruchu Browna $B(1)$, który jest zwyczajnie zmienną ze standardowego rozkładu normalnego $N(0, 1)$. W tej sytuacji wzór na funkcję k sprowadza się do $k(B_i) = e^{-r}(S(1) - K)_+$ dla $i = 1, \dots, R$.

Dla opcji azjatyckiej (gdzie $n > 1$) odcinek $[0, 1]$ dzielimy na n równych części, co może być interpretowane jako analiza ceny co pewien okres np. $n = 12$ - co miesiąc, $n = 4$ - co

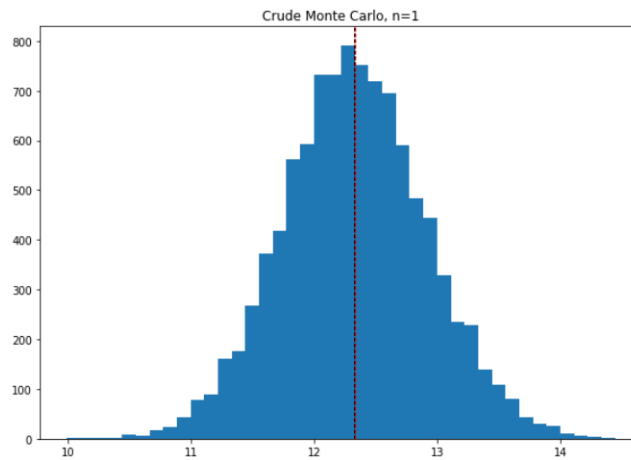
kwartał. Potrzebujemy więc wygenerować R razy ruch Browna dla n punktów. W tym celu wygenerujemy R zmiennych z n -wymiarowego rozkładu normalnego $N(0, \Sigma)$ o macierzy kowariancji

$$\Sigma(i, j) = \text{Cov}(B(t_i), B(t_j)) = \min(t_i, t_j)$$

dla $(t_1, \dots, t_n) = (1/n, \dots, 1)$.

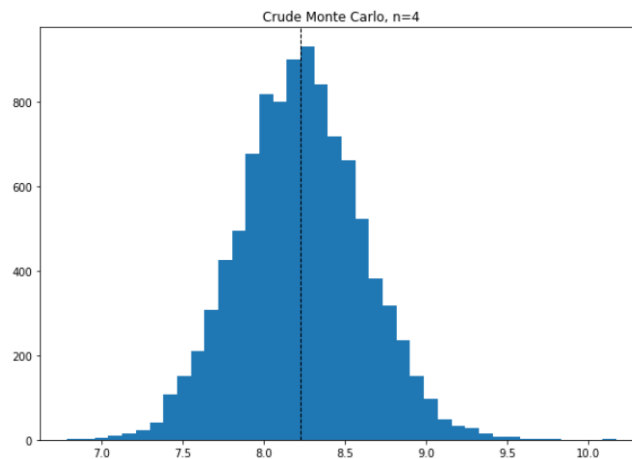
Do obliczeń użyjemy $R = 1000$ i powtórzymy je 10000 razy. Na przedstawionych poniżej histogramach czarną przerywaną linią zaznaczona jest średnia wartość estymatora obliczona w symulacji, natomiast dla $n = 1$ czerwona przerywana linia oznacza wyliczoną wcześniej teoretyczną wartość I .

Opcja europejska, $R = 1000$, 10000 symulacji




Dla powyższej symulacji średnia wartość estymatora wyniosła 12.33 i jak widać na histogramie niemal nakłada się z faktyczną wartością opcji (przerywane linie). Wariancja próbkowa w tym przypadku wyniosła 0.34.

Opcja azjatycka, $n = 4$, $R = 1000$, 10000 symulacji



Opcja azjatycka, $n = 12$, $R = 1000$, 10000 symulacji



Dla symulacji estymatora dla opcji azjatyckiej z $n = 4$ średnia oszacowana wartość wynosi 8.23, a średnia dla $n = 12$ to 7.31. Wariancje dla tych symulacji wyniosły odpowiednio 0.14 i 0.11. Średnie wartości estymatorów porównamy później z wartościami estymatorów w metodzie warstw (inaczej: stratified estimator), ponieważ formuła Blacka-Scholesa daje nam teoretyczny wynik tylko dla $n = 1$.

Wariancja tego estymatora wynosi $Var(\hat{Y}_R^{CMC}) = \frac{1}{R} \sum_{j=1}^R Var(Y_j)$, co zgadza się z wynikami symulacji podczas zmiany R , które zawarte są w poniższych tabelach.

Zależność wariancji estymatora CMC od R dla $n=1$

R	średnia wartość estymatora	wariancja
100	12.39	3.3392
1000	12.35	0.3708
10000	12.33	0.0343

Zależność wariancji estymatora CMC od R dla $n=4$

R	średnia wartość estymatora	wariancja
100	8.25	1.4693
1000	8.25	0.1519
10000	8.23	0.0140

Zależność wariancji estymatora CMC od R dla $n=12$

R	średnia wartość estymatora	wariancja
100	7.31	1.2355
1000	7.31	0.1099
10000	7.31	0.0110

Możemy zauważyć, że wraz ze wzrostem n , średnia wartość estymatora się zmniejsza. Ponadto, otrzymane wyniki są lepsze dla większej liczby obserwacji.

3 Stratified Estimator

Tym razem w celu estymacji $\mathbb{E}[Y] = I$ przyjmijmy, że A^1, \dots, A^m są rozłącznymi zbiorami, dla których zachodzi $\mathbb{P}[Y \in \bigcup_{j=1}^m A^j] = 1$. Owe rozbitcie definiuje warstwy $W^j = \{Y \in A^j\}$, gdzie prawdopodobieństwem wylosowania warstwy jest $p_j = \mathbb{P}[Y \in A^j]$, a $I^j = \mathbb{E}[Y|Y \in A^j]$ ($j = 1, \dots, m$). Mamy

$$\mathbb{E}[Y] = p_1 I^1 + \dots + p_m I^m.$$

Wobec tego, w poszczególnych warstwach będziemy generować zmienne $Y^j =_d (Y|Y \in A_j)$. Estymator I^j definiujemy poprzez

$$\hat{Y}_{R_j}^j = \frac{1}{R_j} \sum_{i=1}^{R_j} Y_i^{R_j},$$

z kolei estymator warstwowy będzie postaci

$$\hat{Y}_R^{str} = p_1 \hat{Y}_{R_1}^1 + \dots + p_m \hat{Y}_{R_m}^m.$$

Zakładając, że $Var(Y^j) = \sigma_j^2$, wariancja otrzymanego estymatora wynosi

$$Var(\hat{Y}_R^{str}) = \sum_{j=1}^m \frac{p_j^2}{R_j} \sigma_j^2$$

Istotnym krokiem będzie właściwy dobór liczby replikacji R_j w warstwach. Mianowicie:

(a) w przypadku *alokacji proporcjonalnej* (używanej, gdy σ_j^2 nie jest znane) mamy

$$R_j = R p_j$$

i przyjmujemy $p_j = 1/m$;

(b) dla zadanych warstw (gdzie p_j oraz σ_j^2 są znane) *optymalnym* doбором będzie

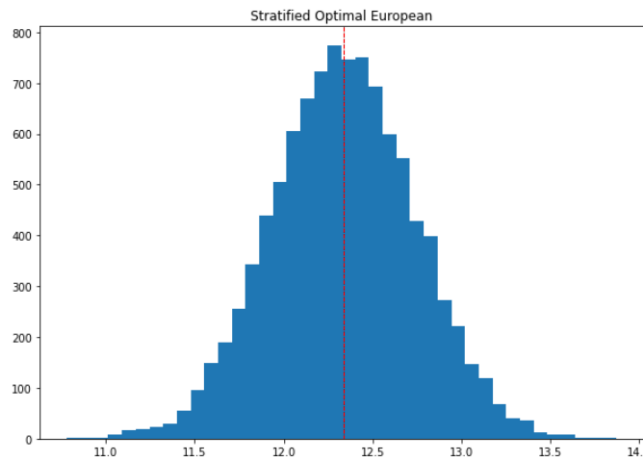
$$R_j = \frac{p_j \sigma_j}{\sum_{i=1}^m p_i \sigma_i} R.$$

Tutaj z kolei najpierw należy wyznaczyć σ_j , które obliczamy jako próbkowe odchylenia standardowe zmiennych Y^j przy użyciu alokacji proporcjonalnej.

3.1 opcja Europejska

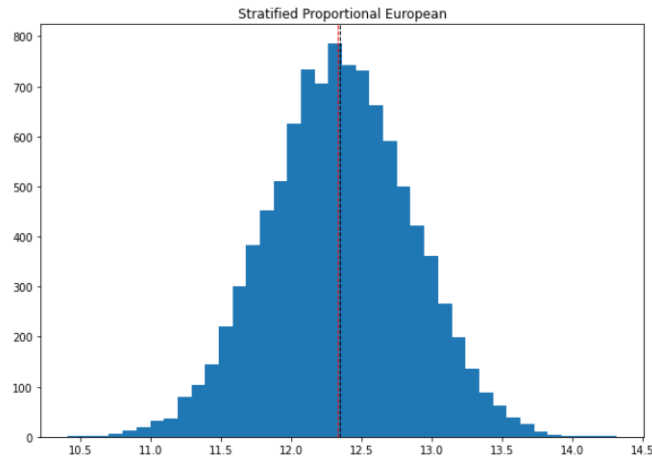
Analizę wyników zaczniemy od opcji Europejskiej, poniżej znajdują się histogramy wartości estymatorów.

Opcja europejska, wariant optimal, R = 1000, 10000 symulacji



Zauważamy pokrycie się linii przerywanej z ciągłą. Oznacza to, że średnia wartość estymatora jest równa wartości rzeczywistej.

Opcja europejska, wariant proportional, $R = 1000, 10000$ symulacji



W tym wariancie obserwujemy już drobne odstępstwo. Badane wartości są sobie nadal bardzo bliskie, ale można zauważyć, że linie przebiegają obok siebie.

Sprawdzamy zachowanie estymatorów dla zmiany ilości losowań R .

Zależność wariancji estymatora Stratified optimal od R dla $n=1$

R	średnia wartość estymatora	wariancja
100	12.33	1.6934
1000	12.32	0.1480
10000	12.34	0.0164

Zależność wariancji estymatora Stratified proportional od R dla $n=1$

R	średnia wartość estymatora	wariancja
100	12.34	2.3947
1000	12.35	0.2529
10000	12.34	0.0252

W obu wariantach średnie wartości estymatora są niemalże takie same, a otrzymana wariancja maleje wraz ze wzrostem R . Ponadto, owe wyniki dla wariancji w przypadku optimal są średnio około 2.5 razy niższe, a w przypadku proportional średnio około 1.5 razy niższe niż odpowiednie wartości uzyskane za pomocą CMC.

W przypadku estymatora warstwowego, możemy również przeanalizować wpływ wyboru ilości warstw na wyniki.

Zależność wariancji estymatora Stratified optimal od m dla $n=1$

R	m	wariancja
1000	5	0.1729
1000	10	0.1589
1000	50	0.1523
10000	5	0.0165
10000	10	0.0144
10000	50	0.0155

W owym wariancie dla ustalonego $R = 1000$ wariancja maleje wraz ze wzrostem m . Gdy R ulega zwiększeniu do 10000, uzyskana wariancja najpierw maleje (wraz ze wzrostem m z 5 do 10), po czym dla $m = 50$ przyjmuje większą wartość.

Zależność wariancji estymatora Stratified proportional od m dla $n=1$

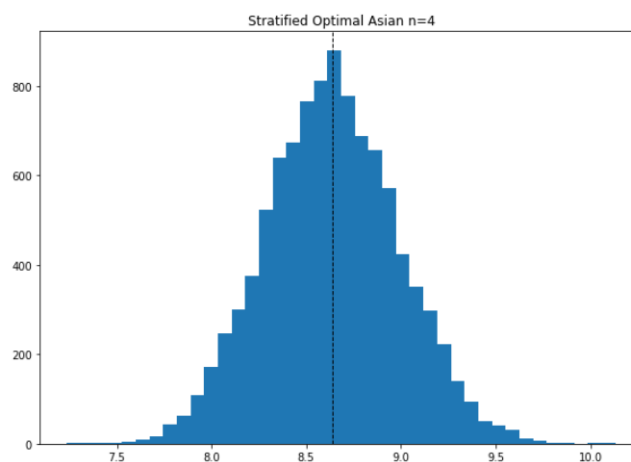
R	m	wariancja
1000	5	0.2573
1000	10	0.2672
1000	50	0.2404
10000	5	0.0286
10000	10	0.0239
10000	50	0.0249

Bez względu na R , dla coraz większego m wariancja ponownie najpierw maleje, z później rośnie.

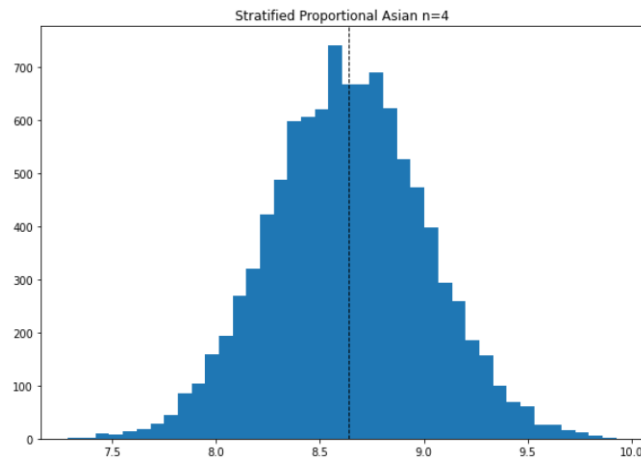
3.2 opcja Azjatycka

Podobnie jak poprzednio, opcję Azjatycką rozpatrzymy dla $n = 4$ oraz $n = 12$.

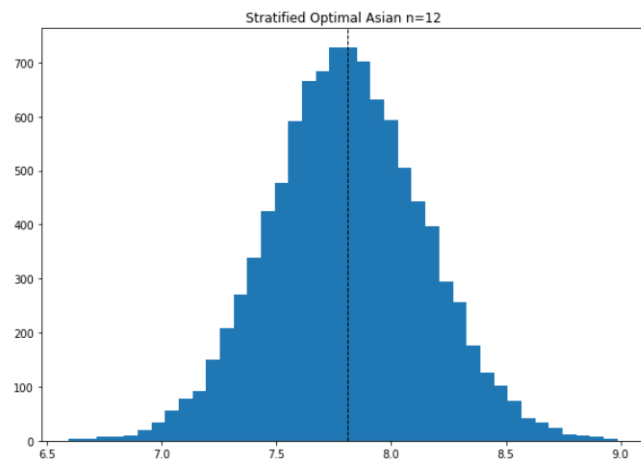
Opcja azjatycka, wariant optimal, $n=4$, $R = 1000$, 10000 symulacji



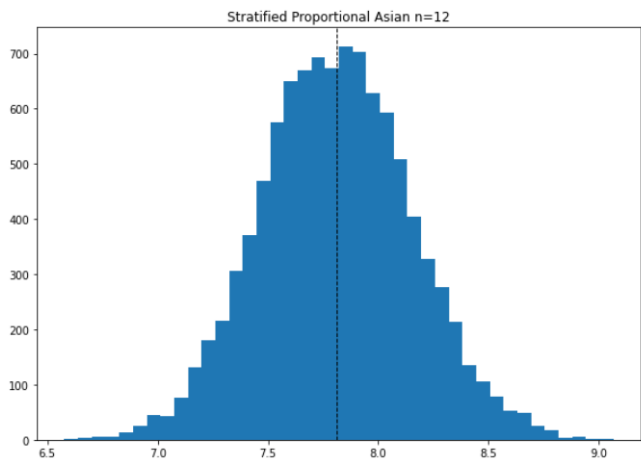
Opcja azjatycka, wariant proportional, $n=4$, $R = 1000$, 10000 symulacji



Opcja azjatycka, wariant optimal, $n=12$, $R = 1000$, 10000 symulacji



Opcja azjatycka, wariant proportional, $n=12$, $R = 1000$, 10000 symulacji



Dla ustalonego n wyniki uzyskane w poszczególnych wariantach są podobne. Mianowicie zarówno dla proportional i optimal, gdy $n = 4$ mamy nieco powyżej 8.5, a gdy n wzrasta do 12 mamy nieco poniżej 8.

Możemy także porównać wariancję dla różnych R z wynikami dla estymatora CMC.

Zależność wariancji estymatora Stratified optimal od R dla $n=4$

R	średnia wartość estymatora	wariancja
100	8.68	1.4552
1000	8.64	0.1211
10000	8.64	0.0123

Zależność wariancji estymatora Stratified optimal od R dla $n=12$

R	średnia wartość estymatora	wariancja
100	7.83	1.4022
1000	7.81	0.1073
10000	7.80	0.0114

Zależność wariancji estymatora Stratified proportional od R dla $n=4$

R	średnia wartość estymatora	wariancja
100	8.65	1.4045
1000	8.64	0.1389
10000	8.64	0.0145

Zależność wariancji estymatora Stratified proportional od R dla $n=12$

R	średnia wartość estymatora	wariancja
100	7.82	1.1081
1000	7.81	0.1228
10000	7.81	0.0112

Dla estymatora Stratified optimal oraz estymatora Stratified proportional, gdy $n = 4$ wyniki wariancji zamieszczone w tabeli prawie pokrywają się z wartościami uzyskanymi w przypadku estymatora CMC, przy czym średnia wartość estymatora jest teraz wyższa. Gdy $n = 12$ wariancja jest bliska (a dla $R = 10000$ prawie identyczna) wariancji otrzymanej w metodzie CMC dla owej liczby n . Tym razem średnia wartość estymatora ponownie jest wyższa.

Sprawdzimy również jak na wyniki w tym wypadku wpływa wybór ilości warstw m .

Zależność wariancji estymatora Stratified optimal od m dla $n=4$

R	m	wariancja
1000	5	0.1271
1000	10	0.1221
1000	50	0.1186
10000	5	0.0134
10000	10	0.0115
10000	50	0.0119

Zależność wariancji estymatora Stratified optimal od m dla $n=12$

R	m	wariancja
1000	5	0.1096
1000	10	0.1046
1000	50	0.1238
10000	5	0.0114
10000	10	0.0107
10000	50	0.0119

Zależność wariancji estymatora Stratified proportional od m dla $n=4$

R	m	wariancja
1000	5	0.1407
1000	10	0.1331
1000	50	0.1522
10000	5	0.0134
10000	10	0.0134
10000	50	0.0142

Zależność wariancji estymatora Stratified proportional od m dla $n=12$

R	m	wariancja
1000	5	0.1153
1000	10	0.1239
1000	50	0.1223
10000	5	0.0110
10000	10	0.0116
10000	50	0.0120

Wraz ze wzrostem warstw dla estymatora Stratified optimal ($n = 4$) zauważamy spadek wariancji przy ustalonym $R = 1000$, natomiast w wariancie proportional, gdy $R = 10000$ zaobserwować można łagodny wzrost wartości wariancji. W pozostałych przypadkach nie ma wyraźnie zarysowanej tendencji.

4 Antithetic Estimator

Inną metodą symulacji $I = \mathbb{E}[Y]$ jest metoda antyetyczna, która nie zakłada niezależności replikacji. Rozważymy ją jedynie dla opcji europejskiej. Weźmy parzystą liczbę R zmiennych losowych Y_1, \dots, Y_R i załóżmy, że pary (Y_{2i-1}, Y_{2i}) , $i = 1, \dots, \frac{R}{2}$ są niezależne i pochodzą z tego samego rozkładu, oraz rozkład brzegowy zmiennych losowych $(Y_i)_{i=1}^R$ jest taki sam jak Y .

Wówczas estymator antytetyczny będzie postaci


$$\hat{Y}_R^{anth} = \frac{1}{R} \sum_{i=1}^R Y_i.$$

Wtedy jego wariancja wynosi

$$Var(\hat{Y}_R^{anth}) = \frac{\frac{R}{2} Var(Y_1 + Y_2)}{R^2} = \frac{1}{R} Var(Y)(1 + corr(Y_1, Y_2)),$$

zatem przy $corr(Y_1, Y_2) < 0$ wariancja estymatora zostanie zmniejszona w stosunku do estymatora CMC. W projekcie jako nasze pary zmiennych losowych weźmiemy (Z_{2i-1}, Z_{2i}) , przy czym $Z_{2i} = -Z_{2i-1}$, a $Z_{2i-1}, i = 1, \dots, \frac{R}{2}$ są iid i pochodzą z rozkładu normalnego $N(0, 1)$. Funkcja k jest taka jak wcześniej, a przy obliczaniu $S(1)$ zamiast zmiennych $B(1)_i$ bierzemy zmienne Z .

Opcja europejska, $R = 1000, 10000$ symulacji



W symulacji ponownie średnia wartość estymatora pokrywa się niemal idealnie z wartością teoretyczną, co widać jako pokrycie się linii na powyższym histogramie. Wariancja w tym przypadku powinna wyjść dużo mniejsza niż dla estymatora CMC, ponieważ tak zdefiniowane zmienne Z jak powyżej mają współczynnik korelacji równy -1 . I faktycznie, teraz wariancja wynosi 0.19, czyli prawie dwukrotnie mniej niż przy CMC, zatem obserwujemy znaczną poprawę przy zachowanej dokładności wyniku. Również tak samo jak poprzednio, im większe R , tym mniejsza wariancja, ponieważ tak samo licząc wariancję mamy wyraz $\frac{1}{R}$.

Zależność wariancji estymatora antytetycznego od R

R	średnia wartość estymatora	wariancja
100	12.36	1.9512
1000	12.35	0.1950
10000	12.34	0.0180

5 Control Variate Estimator

Ostatnią metodą jest control variate method czyli metoda zmiennych kontrolnych. Opiera się ona na jednoczesnym symulowaniu drugiej zmiennej losowej X , dla której wartość oczekiwana jest znana. Wobec tego otrzymujemy niezależne pary postaci $(Y_1, X_1), \dots, (Y_R, X_R)$. Załóżmy, że $\hat{X}_R = \frac{1}{R} \sum_{i=1}^R X_i$, wówczas

$$\hat{Y}_R^{CV} = \hat{Y}_R^{CMC} + c(\hat{X}_R - \mathbb{E}[X]),$$

przy czym

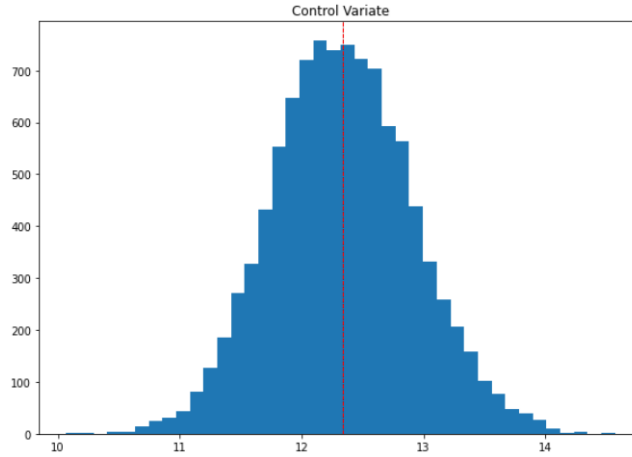
$$c = -\frac{Cov(Y, X)}{Var(X)}$$

i c jest dobrane tak, aby wariancja była minimalna.

Ponownie rozpatrujemy jedynie europejską opcję, gdzie $B(1)$ o standardowym rozkładzie normalnym stanowić będzie zmienną losową X . Skoro $X \sim N(0, 1)$ to wiemy, że $E[X] = 0$ oraz $Var(X) = 1$. Dlatego dla takiego wyboru zmiennej X wzór na estymator sprowadza się do:

$$\hat{Y}_R^{CV} = \hat{Y}_R^{CMC} - Cov(Y, X)(\hat{X}_R)$$

Opcja europejska, $R = 1000$, 10000 symulacji



Również w tym wypadku średnia wartość estymatora wynosi 12.34 i widać, że zgadza się z wartością teoretyczną. Natomiast wariancja wynosi tutaj 0.33 czyli jedynie minimalnie mniej niż wariancja przy CMC. Licząc wariancję teoretycznie otrzymujemy

$$\begin{aligned} Var(\hat{Y}_R^{CV}) &= \frac{Var(Y + cX)}{R} = \\ &= \frac{1}{R}(Var(Y) + c^2 Var(X) + 2c Cov(X, Y)) = \\ &= \frac{1}{R} \left(Var(Y) - \frac{Cov(X, Y)^2}{Var(X)} \right). \end{aligned} \quad (2)$$

U nas $Var(X) = 1$, zatem $Var(\hat{Y}_R^{CV}) = \frac{1}{R}(Var(Y) - Cov(X, Y)^2)$, co wskazuje na to, że im bardziej zmienne X oraz Y są niezależne, tym bardziej wariancja będzie zbliżona do tej otrzymywanej przy użyciu estymatora CMC. W naszym wypadku zmienne X_i losowane są niezależnie od Y_i , więc faktycznie nie powinny mieć wysokiej korelacji, także symulacja zgadza się z oczekiwaniami. Ponownie widzimy wyrażenie element $\frac{1}{R}$ przy wzorze na wariancję estymatora, co można zaobserwować również w wynikach symulacji przedstawionych poniżej. Zauważamy też, że niezależnie od R , wariancja wciąż jest tylko minimalnie mniejsza niż ta przy estymacji metodą CMC.

Zależność wariancji estymatora CV od R

R	średnia wartość estymatora	wariancja
100	12.42	3.4478
1000	12.34	0.3294
10000	12.33	0.0321

Literatura

- [1] Tomasz Rolski, *Symulacje stochastyczne i teoria Monte Carlo*, <http://www.math.uni.wroc.pl/~rolski/Zajecia/sym.pdf>
- [2] Projekt, *Introduction to simulations and Monte Carlo methods. Project nr 2*, https://moodle.math.uni.wroc.pl/pluginfile.php/17722/mod_resource/content/2/2022_monte_carlo_project2.pdf