Uniwersytet Wrocławski
Wydział Matematyki i Informatyki
Instytut Matematyczny
specjalność: matematyka stosowana

Zuzanna Brzóska

Matematyczny model zachowań przestępczych

Praca magisterska
napisana pod kierunkiem
prof. dr. hab. Grzegorza Karcha

Wrocław 2023

Abstract

This thesis presents a deterministic mathematical model for burglaries. The goal is to analyze the model mathematically and through numerical simulations, examining criminal density, house attractiveness, and the effect of diffusion. The thesis explores the discrete and continuous versions of the model, analyzes the system without criminal agents, investigates stability without diffusion and after its reintroduction, as well as presents numerical simulations. The main result is the identification of Turing's instability within this model.

Streszczenie

Niniejsza praca dyplomowa prezentuje deterministyczny model matematyczny opisujący włamania. Celem jest analiza tego modelu matematycznie oraz poprzez symulacje numeryczne, badając gęstość przestępców i atrakcyjność domów, a także efekt dyfuzji. Praca ta bada dyskretną i ciągłą wersję modelu, analizuje system bez agentów przestępczych, bada stabilność bez dyfuzji oraz po jej ponownym wprowadzeniu oraz prezentuje symulacje numeryczne. Głównym rezultatem jest zidentyfikowanie niestabilności Turinga w tym modelu.

Spis treści

1 Wstęp **4**

2 Wprowadzenie do modelu **4**
2.1 Model dyskretny 4
2.2 Model ciągły 6

3 Analiza matematyczna modelu ciągłego **7**
3.1 Granica atrakcyjności przy braku agentów 7

4 Rozwiązanie jednorodne przestrzennie **9**
4.1 Stany stacjonarne 10
4.2 Stabilność 10
4.3 Portret fazowy 12

5 Niestabilność Turinga **14**
5.1 Analiza matematyczna 14

6 Symulacje numeryczne modelu **17**
6.1 Na odcinku $[0,l]$ 17
6.1.1 Symulacje modelu dla różnych warunków początkowych 17
6.1.2 Zmiany parametrów 20
6.2 Na kwadracie $[0, l] \times [0, l]$ 23

7 Dodatek programistyczny **28**

1 Wstęp

Badaniem zachowań przestępczych zajmuje się wiele dziedzin, takich jak socjologia, kryminologia czy matematyka. W kontekście matematycznym, powszechne jest stosowanie modeli stochastycznych do opisu zachowań ludzkich. Jednak zespół badaczy z Uniwersytetu w Kalifornii stworzył model deterministyczny, skupiając się na zachowaniu włamywaczy, jak opisano w pracach [4, 3].

Celem niniejszej pracy magisterskiej jest analiza matematyczna tego modelu, opisującego gęstość przestępców i atrakcyjność domów, oraz efektu dyfuzji, a także symulacje numeryczne. Struktura niniejszej pracy jest następująca: wyjaśnienie modelu dyskretnego i jego ciągłej wersji, analiza modelu bez agentów przestępczych, badania zachowania systemu w ich nieobecności, analiza modelu pozbawionego elementu dyfuzji oraz analiza stabilności po przywróceniu dyfuzji (niestabilność Turinga) i w części końcowej prezentacja wyników symulacji numerycznych w celu potwierdzenia i zobrazowania zachowania modelu.

2 Wprowadzenie do modelu

W analizie zachowań przestępczych istnieje model matematyczny opisujący dynamikę ruchu ognisk włamań do mieszkań, czyli miejsc zagęszczenia działań przestępczych. Okazuje się, że przez pewien czas po pierwszym włamaniu istnieje zwiększone prawdopodobieństwo ponownego włamania do danego obiektu. W rezultacie możemy zauważyć, że włamania są niejednostajnie rozłożone w przestrzeni i częściej występują w niektórych dzielnicach.

2.1 Model dyskretny

Aby opisać to zjawisko, wykorzystać można modelowanie agentowe, gdzie system jest reprezentowany jako zbiór autonomicznych jednostek decyzyjnych, nazywanych agentami, w naszym przypadku są to przestępcy. Model opiera się na założeniu, że jednostki przestępcze poruszają się losowo po dwuwymiarowej siatce i dokonują włamań, gdy tylko nadarza się okazja. Każdemu obiektowi przypisywana jest wartość atrakcyjności (oznaczaną jako $A(x,t)$), odnosząca się do łatwości włamania się do niego przy minimalnych konsekwencjach. Oprócz ruchu losowego, występuje również ruch tendencyjny w kierunku obszarów o większej wartości atrakcyjności. Ponadto prędkość tego ruchu jest odwrotnie proporcjonalna do wartości atrakcyjności w ich bieżącej pozycji (prędkość ruchu związana jest również z odstępem siatki l).

Rozważamy obszar działań przestępców jako dwuwymiarową siatkę z rozmieszczeniem o odstępie l, a na niej pole skalarne $A(x,t)$, opisujące atrakcyjność poszczególnych lokalizacji, oraz przestępcze działania, które odbywają się w dyskretnych momentach czasowych z krokiem δt. W każdym momencie t istnieje prawdopodobieństwo p_v, że przestępcy dokonają napadu na określoną lokalizację x, zgodnie ze standardowym procesem Poissona o wartości oczekiwanej $A(x,t)\delta t$":

$$p_v(x,t) = 1 - e^{-A(x,t)\delta t}.$$

Jeżeli przestępstwo zostanie popełnione, przestępca, który je popełnił, zostaje usunięty z obszaru. W przeciwnym przypadku, przenosi się on do jednego z miejsc sąsiadujących z jego obecną lokalizacją x. Przyjmujemy, że wybór sąsiada y dla aktualnej lokalizacji odbywa się zgodnie z procesem błądzenia losowego i jest dokonywany z prawdopodobieństwem p_m, które jest określone jako

$$p_m(y,t;x) = \frac{A(y,t)}{\sum_{x' \ x} A(x',t)},$$

gdzie x' opisuje wszystkie obszary sąsiadujące z x.

Wartość pola $A(x,t)$ możemy przedstawić jako sumę pewnej stałej, być może przestrzennie niejednorodnej wartości pola A_0, oraz dynamicznego składnika $B(x,t)$, który zmienia się w czasie i zależy od napaści, mających miejsce w sąsiedztwie jak i w samej lokalizacji x. Nasze zainteresowanie skupia się więc na zachowaniu się składnika $B(x,t)$.

Zgodnie z wcześniejszym opisem zachowań, wiemy, że wraz z każdym zdarzeniem atrakcyjność wzrasta. Dlatego też, wraz z każdym krokiem czasowym, wartość $B(x,t)$ zwiększa się o określoną wielkość θ, zwielokrotnioną o $E(x,t)$ - liczbę napaści, które miały miejsce od chwili rozpoczęcia momentu t. Jednakże, zwiększona atrakcyjność zmniejsza się wraz z upływem czasu. Wprowadzamy więc wartość ω, określającą skalę czasową, w której najprawdopodobniej wystąpić może powtórna wiktymizacja.

Łącząc wzrost atrakcyjności po wystąpieniu zdarzenia oraz zanikanie atrakcyjności w czasie, możemy opisać zachowanie $B(x,t)$ jako

$$B(x,t+\delta t) = B(x,t)(1-\omega\delta t) + \theta E(x,t).$$

Przy uwzględnieniu rozprzestrzeniania się jednostek przestępczych na 4 sąsiadujące obszary i dodaniu tej informacji do modelu (poprzez dodanie parametru η określającego efekt sąsiadów), otrzymujemy ostatecznie równanie opisujące zachowanie $B(x,t)$ w czasie, uwzględniające wszystkie zaobserwowane zachowania:

$$B(x,t+\delta t) = \left[(1-\eta)B(x,t) + \tfrac{\eta}{4}\sum_{x'\sim x} B(x',t)\right](1-\omega\delta t) + \theta E(x,t). \tag{1}$$

Stąd nasz model dyskretny opisujący zmianę atrakcyjności $A(x,t)$ prezentuje się w poniższy sposób:

$$A(x,t+\delta t) = \left[(1-\eta)B(x,t) + \tfrac{\eta}{4}\sum_{x'\sim x} B(x',t)\right](1-\omega\delta t) + \theta E(x,t) + A^0. \tag{2}$$

2.2 Model ciągły

Możemy rozszerzyć powyższe dyskretne równanie poprzez dodanie równania opisującego liczbę kryminalistów $n(x,t)$ w czasie t i miejscu x. Wiemy, że liczba kryminalistów obecnych w miejscu x w czasie t pochodzi albo z lokacji sąsiednich od kryminalistów, którzy nie zdecydowali się tam na akcję, lub z nowo wygenerowanych agentów, którzy tworzeni są w tempie Δ. Otrzymujemy więc wzór

$$n(x,t+\delta t) = A(x,t)\sum_{x'\sim x}\frac{n(x',t)[1-p_v(x',t)]}{\sum_{x''\sim x'} A(x'',t)} + \Gamma\delta t.$$

Uśredniając liczbę $n(x,t)$ jako gęstość $\rho(x,t)$ oraz przechodząc do granicy z δt i l w obu równaniach, otrzymujemy ostatecznie następujący model, składający się z układu dwóch równań różniczkowych cząstkowych opisujących $A(x,t)$ i $\rho(x,t)$, odpowiednio wartość atrakcyjności i gęstość przestępczości:

$$\frac{\partial A}{\partial t} = \eta\Delta A - A + A\rho + A^0 \tag{3a}$$

$$\frac{\partial \rho}{\partial t} = \Delta\rho - 2\nabla\cdot[\rho\nabla\chi(A)] + R - A\rho \tag{3b}$$

Układ ten rozważamy na obszarze $\Omega \subset \mathbb{R}^n$, uzupełniony warunkami początkowymi

$$A(x,0) = A_0(x)$$
$$\rho(x,0) = \rho_0(x)$$

i warunkami brzegowymi

$$v \cdot \nabla A\,|_{\partial\Omega} = 0$$
$$v \cdot \nabla \rho\,|_{\partial\Omega} = 0\ ,$$

gdzie v jest zewnętrznym wektorem normalnym i warunki brzegowe braku przepływu pochodzą od założenia, że mniej więcej taka sama liczba kryminalistów opuszcza obszar oraz do niego napływa.

Równanie (3a) mówi nam, że wartość atrakcyjności A dyfunduje z bezwymiarowym współczynnikiem dyfuzji η ($\leqslant 1$) oraz w miarę upływu czasu zanika wykładniczo do wartości bazowej A^0, co odzwierciedla wpływ sąsiadów oraz ograniczony czas zwiększonej atrakcyjności po poprzednich włamaniach. Liczba włamań popełnionych lokalnie dana jest poprzez $A\rho$, a wraz z każdym włamaniem wartość atrakcyjności wzrasta.

W równaniu (3b) gęstość przestępczości również ulega dyfuzji, ponieważ jednostki kryminalne są w ruchu. Funkcję $\chi(A)$ możemy nazwać "funkcją wrażliwości"i bezpośrednio z modelu dyskretnego wynika, że $\chi(A) = \log(A)$, jednak można rozważać również inne funkcje. Ten element równania związany jest z ruchem tendencyjnym przestępców w kierunku zwiększonej atrakcyjności z prędkością odwrotnie proporcjonalnej do wartości atrakcyjności w ich aktualnej lokalizacji. Ponadto, jednostki przestępcze pojawiają się w stałym tempie R i są usuwane z modelu po dokonaniu włamania.

3 Analiza matematyczna modelu ciągłego

3.1 Granica atrakcyjności przy braku agentów

Przeanalizujmy zachowanie rozwiązania równania 3 przy założeniu $\rho \equiv 0$ w granicy $t \to \infty$. Pokażemy, że gdy w obszarze nie występują włamywaczy, atrakcyjność stabilizuje się na poziomie A^0.

Twierdzenie 3.1. *Załóżmy, że $A^0 \equiv const$. Dla dowolnych warunków początkowych $A_0 \in C([0,1])$, gdy $A(x,t)$ jest rozwiązaniem zagadnienia*

$$\begin{array}{l} \frac{\partial A}{\partial t} = \eta \frac{\partial^2 A}{\partial x^2} - A + A^0 \\ \frac{\partial A}{\partial x} = 0 \quad x \in \{0,1\} \\ A(x,0) = A_0(x) \end{array} \tag{4}$$

zachodzi

$$\sup_{x\in[0,1]} |A(x,t) - A^0| \to 0,$$

gdy $t \to \infty$.

Dowód. Oczywiście $A \equiv A^0$ jest stanem stacjonarnym. W celu pokazania powyższego twierdzenia, wprowadzamy $W(x,t)$ takie, że

$$W(x,t) = A(x,t) - A^0,$$

które spełnia zagadnienie

$$\begin{array}{l} \frac{\partial W}{\partial t} = \eta \Delta W - W \\ \frac{\partial W}{\partial x} = 0 \quad x \in \{0,1\} \\ W(x,0) = W_0(x) = A_0(x) - A^0 \end{array} \tag{5}$$

Rozwiązanie powyższego równania znajdziemy używając metody szeregów Fouriera.

Załóżmy, że $W(x,t) = X(x)T(t)$, wtedy

$$X(x)T'(t) = \eta X''(x)T(t) - X(x)T(x),$$

inaczej

$$\frac{T' + T}{\eta T} = \frac{X''}{X} = -\lambda.$$

Stąd wynikają dwa równania różniczkowe zwyczajne: $X'' + \lambda X = 0$ z warunkami brzegowymi Neumanna $X'(0) = X'(1) = 0$ oraz $T' + (1 + \lambda\eta)T = 0$. Skupimy się najpierw na pierwszym z nich.

Dla $\lambda < 0$ nie istnieją nietrywialne rozwiązania. Gdy $\lambda = 0$, biorąc pod uwagę warunki brzegowe, otrzymujemy że $X(x) = A$ dla pewnej stałej A. Natomiast w przypadku $\lambda > 0$, rozwiązanie jest postaci $X(x) = A\cos\sqrt{\lambda x} + B\sin\sqrt{\lambda x}$. Uwzględniając warunki brzegowe dostajemy $X(x) = A\cos\sqrt{\lambda x}$ oraz warunek $A\sin\sqrt{\lambda} = 0$, który zachodzi wtedy i tylko wtedy, gdy $\lambda = \pi^2 k^2$ dla $k = 1, 2, \ldots$. Łącząc wszystkie możliwości, otrzymujemy rozwiązania:

$$X_k(x) = A_k \cos(\pi k x) \quad \text{dla } k = 0, 1, 2, ...$$

Teraz wróćmy do drugiego równania $T' + (1 + \lambda\eta)T = 0$. Dla znalezionych powyżej dozwolonych wartości λ, rozwiązaniem tego równania jest $T(t) = c_k e^{-t(1+\pi^2 k^2 \eta)}$.

Łącząc rozwiązania równań dla X oraz T oraz wprowadzając oznaczenie $b_k = A_k c_k$ otrzymujemy, że zagadnienie (5) ma rozwiązanie postaci:

$$W(x,t) = \sum_{k=0}^{\infty} b_k e^{-t(1+\pi^2 k^2 \eta)} \cos(\pi k x).$$

Współczynniki b_k wyznaczamy z warunku początkowego:

$$W(x,0) = \sum_{k=0}^{\infty} b_k \cos(\pi k x).$$

Jest to szereg Fouriera dla funkcji *cosinus*, zatem znamy wzór na b_k:

$$b_k = \begin{cases} \int_0^1 W_0(x)dx, & k = 0 \\ 2\int_0^1 W_0(x)\cos(\pi k x)dx, & k = 1, 2, \ldots . \end{cases}, \tag{6}$$

Współczynniki b_k możemy więc ograniczyć z góry w następujący sposób

$$|b_n| \leqslant 2 \max_{x\in[0,1]} |W_0(x)|.$$

Dzięki temu możemy ograniczyć z góry rozwiązanie $W(x,t)$, mianowicie:

$$|W(x,t)| = |\sum_{k=0}^{\infty} b_k e^{-t(1+\pi^2 k^2 \eta)} \cos(\pi k x)| \tag{7}$$

$$\leqslant 2 \max_{x\in[0,1]} |W_0(x)| |e^{-t} \sum_{k=0}^{\infty} e^{-t\pi^2 k^2 \eta}| \tag{8}$$

$$\leqslant 2 \max_{x\in[0,1]} |W_0(x)| |e^{-t} \frac{1}{1-e^{-t\pi^2\eta}}|, \tag{9}$$

gdzie oczywiście $2\max_{x\in[0,1]} |W_0(x)|$ jest ograniczone, ponieważ $W_0(x) = A_0(x) - A^0$ oraz $A_0(x) \in C([0,1])$, natomiast $\frac{e^{-t}}{1-e^{-t\pi^2\eta}}$ dąży do 0 gdy t dąży do nieskończoności.

W rezultacie, w granicy $t \to \infty$, otrzymujemy $W(x,t) \to 0$, co z kolei implikuje $A(x,t) \to A^0$.

□

4 Rozwiązanie jednorodne przestrzennie

Przeprowadzimy teraz analizę układu jednorodnego przestrzennie, czyli przy założeniach $A(x,t) = A(t)$ oraz $\rho(x,t) = \rho(t)$. Układ sprowadza się teraz do postaci

$$\begin{cases} A' = -A + A\rho + A^0 \\ \rho' = R - A\rho. \end{cases} \tag{10}$$

4.1 Stany stacjonarne

Aby wyznaczyć stany stacjonarne, przyrównujemy pochodne do zera i rozwiązujemy poniższy układ równań

$$\begin{cases} -A + A\rho + A^0 = 0 \\ R - A\rho = 0. \end{cases} \tag{11}$$

Otrzymujemy stany stacjonarne równe:

$$\hat{A} = A^0 + R \quad \text{oraz} \quad \hat{\rho} = \frac{R}{A^0 + R}.$$

4.2 Stabilność

Twierdzenie 4.1. *Dla $A^0, R \geqslant 0$ rozwiązanie $\hat{A} = A^0 + R, \hat{\rho} = \frac{R}{A^0+R}$ układu (10) jest asymptotycznie stabilne.*

Dowód. W celu sprawdzenia stabilności znalezionego stanu stacjonarnego, należy najpierw policzyć Jakobian układu (10) w punkcie $(\hat{A}, \hat{\rho})$, a następnie znaleźć jego wartości własne. Jakobian dla tego układu, w punkcie $(\hat{A}, \hat{\rho})$, jest postaci:

$$\begin{bmatrix} -1 + \hat{\rho} & \hat{A} \\ -\hat{\rho} & -\hat{A} \end{bmatrix},$$

a jego równanie charakterystyczne wynosi:

$$\lambda^2 + \lambda(\hat{A} + 1 - \hat{\rho}) + \hat{A} = 0,$$

skąd otrzymujemy wartości własne wynoszące:

$$\lambda = \frac{1}{2}(\hat{\rho} - \hat{A} - 1) \pm \sqrt{\hat{A}^2 + \hat{\rho}^2 - 2\hat{A}\hat{\rho} - 2\hat{A} - 2\hat{\rho} + 1}.$$

Układ jest stabilny, gdy dla każdej wartości własnej zachodzi $Re(\lambda) < 0$, zatem w naszym przypadku gdy

$$\hat{\rho} - \hat{A} - 1 < 0 \quad \text{oraz} \quad \hat{A}^2 + \hat{\rho}^2 - 2\hat{A}\hat{\rho} - 2\hat{A} - 2\hat{\rho} + 1 \leqslant 0 \tag{12}$$

lub gdy

$$\hat{\rho} - \hat{A} - 1 < \sqrt{\hat{A}^2 + \hat{\rho}^2 - 2\hat{A}\hat{\rho} - 2\hat{A} - 2\hat{\rho} + 1} \quad \text{oraz} \quad \hat{A}^2 + \hat{\rho}^2 - 2\hat{A}\hat{\rho} - 2\hat{A} - 2\hat{\rho} + 1 > 0. \tag{13}$$

Warunki te zaznaczone są na poniższym wykresie:

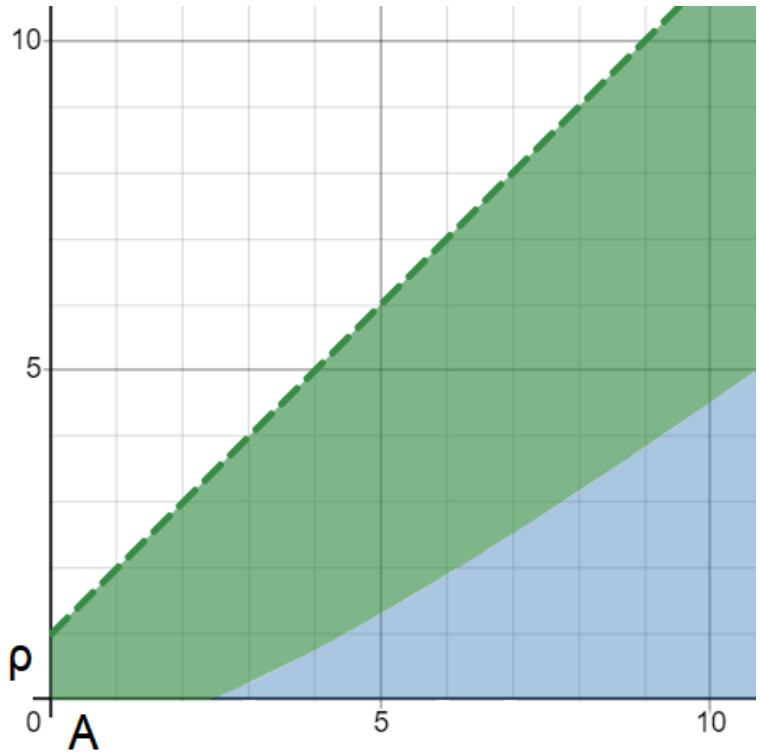

Rysunek 1: Pole zielone obrazuje warunek (12), pole niebieskie warunek (13). Przerywana prosta wyznacza prostą $\rho - A - 1 = 0$. Dla wszystkich punktów stacjonarnych powyżej tej prostej układ jest niestabilny.

Zauważmy jednak, że wyznaczając parametry A^0 oraz R z wyznaczonego stanu stacjonarnego otrzymujemy, że $A^0 = \hat{A} - \hat{A}\hat{\rho}$ oraz $R = \hat{A}\hat{\rho}$, a biorąc pod uwagę znaczenie tych parametrów w rzeczywistości chcielibyśmy, aby były one nieujemne, co ogranicza nam dodatkowo zbiór stanów stacjonarnych. Na następnym wykresie dodany jest również ten warunek.

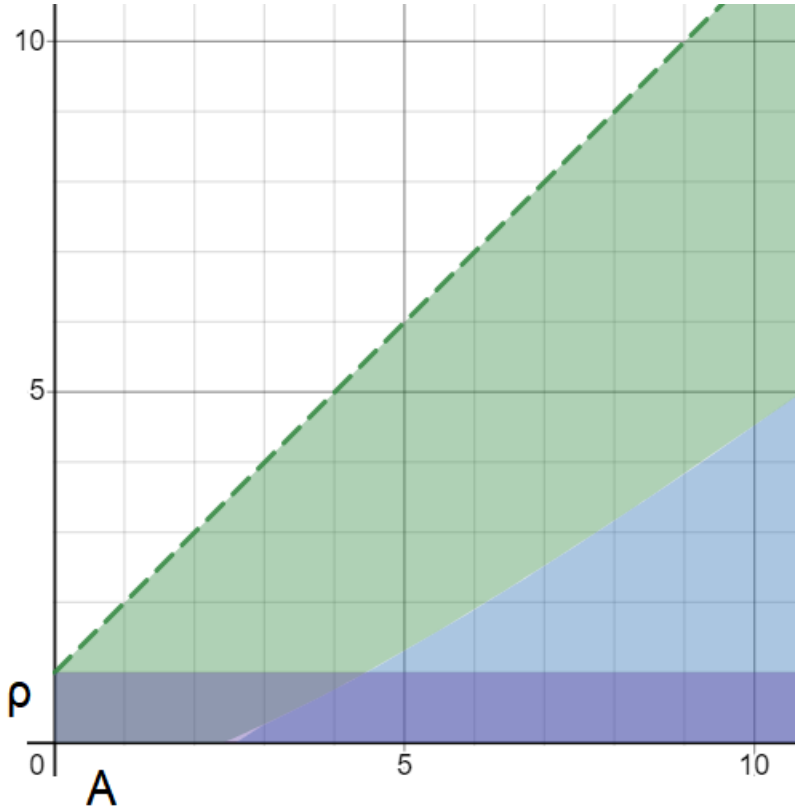

Rysunek 2: Pola zielone i niebieskie obrazują warunki (12) i (13), natomiast pole fioltowe wyznacza gdzie spełnione jest $A^0, R \geqslant 0$.

Obserwujemy, że wszystkie stany stacjonarne odpowiadające nieujemnym parametrom będą asymptotycznie stabilne.

□

4.3 Portret fazowy

Określoną wcześniej stabilność można zaobserwować na portrecie fazowym. Na poniższym rysunku przedstawione są portrety fazowe modelu (10) dla różnych punktów stacjonarnych:

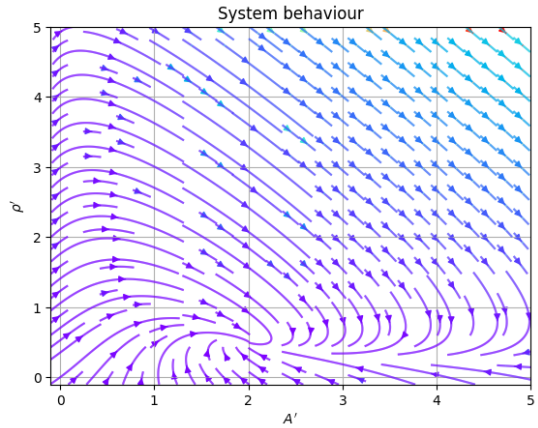

(a) $\hat{A} = 2, \hat{\rho} = 0.5$

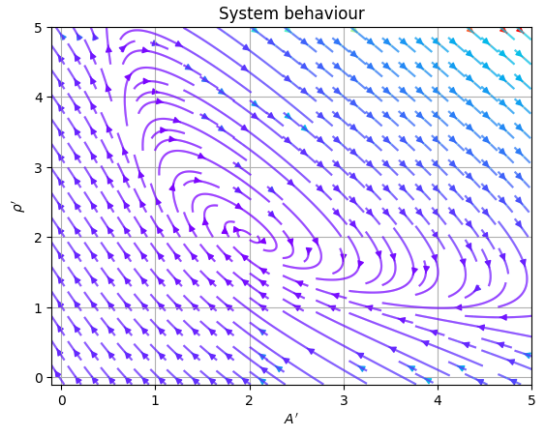

(b) $\hat{A} = 2, \hat{\rho} = 2$

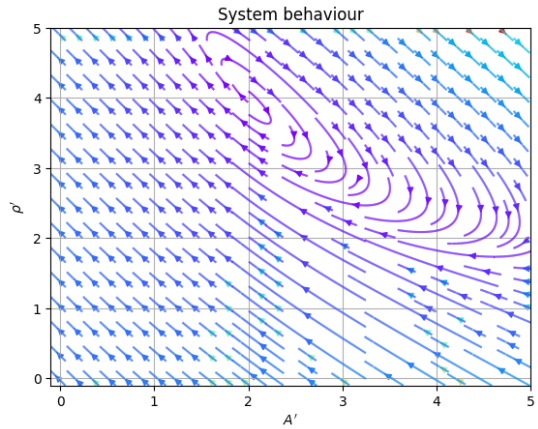

(c) $\hat{A} = 2, \hat{\rho} = 4$

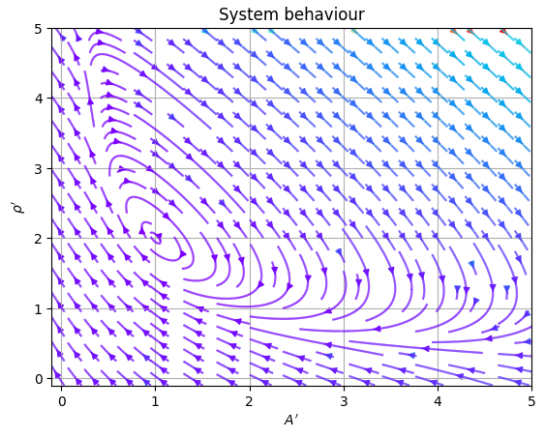

(d) $\hat{A} = 2, \hat{\rho} = 3$

Rysunek 3: Na wykresie (a) obserwujemy stabilny stan stacjonarny, odpowiadający realnym wartościom parametrów $A^0 = 1, R = 1$. Na wykresie (b) stan stacjonarny również jest stabilny, natomiast odpowiada wartościom parametrów $A^0 = -2, R = 4$, które nie są interesujące ze względu interpretacji modelu. Na obrazku (c) obserwujemy niestabilny stan stacjonarny, odpowiadający nierealnym wartościom parametrów $A^0 = -6, R = 8$. Możemy również sprawdzić co dzieje się gdy stan stacjonarny znajduje się na prostej $\hat{\rho} - \hat{A} - 1 = 0$, obrazek (d) ukazuje ten przypadek, obserwujemy na nim stabilność układu.

Wszystkie powyższe symulacje zgadzają się z wcześniejszymi wnioskami.

5 Niestabilność Turinga

5.1 Analiza matematyczna

Przypomnijmy, że stałe rozwiązanie stacjonarne $(\hat{A}, \hat{\rho})$ jest stabilne w układzie bez dyfuzji. Z analizy w poprzednim rozdziale, zachodzi to dla wszystkich nieujemnych wartości A^0, R, czyli gdy $\hat{A}, \hat{\rho}$ leży pod prostą $\hat{\rho} - \hat{A} = 1$. Mówimy, że rozwiązanie $(\hat{A}, \hat{\rho})$ jest niestabilne w sensie Turinga, gdy jest ono niestabilne dla układu z dyfuzją. W tym rozdziale pokażemy, że w układzie 3 występuje niestabilność Turinga.

Aby sprawdzić występowanie niestabilności Turinga potrzebujemy najpierw zlinearyzować równania naszego układu. W tym celu wprowadzamy nowe zmienne

$$\phi(x,t) = A(x,t) - \hat{A}$$
$$\psi(x,t) = \rho(x,t) - \hat{\rho}$$

i wstawiamy $A = \phi + \hat{A}, \rho = \psi + \hat{\rho}$ do oryginalnego układu.

Podstawiając $A = \phi + \hat{A}$ oraz $\rho = \psi + \hat{\rho}$ do pierwszego równania i zostawiając tylko wyrazy pierwszego rzędu, otrzymujemy że ϕ spełnia równanie

$$\phi_t = \eta\phi_{xx} + \hat{A}\psi + \hat{\rho}\phi.$$

Następnie robimy to samo podstawienie w drugim równaniu, jednak najpierw rozwijamy funkcję $\chi(\psi)$ w szereg Taylora w punkcie $\hat{A}$, która bez uwzględnienia wyrazów wyższego rzędu, wynosi $\ln(\psi + \hat{A}) = \ln(\hat{A}) + \phi/\hat{A}$. W rezultacie drugie równanie, po usunięciu wyrazów wyższego rzędu, przyjmuje postać:

$$\psi_t = \psi_{xx} - 2\hat{\rho}\frac{1}{\hat{A}}\phi_{xx} - \hat{\rho}\phi - \hat{A}\psi.$$

Będziemy badać stabilność rozwiązania $(\phi, \psi) = (0,0)$ układu zlinearyzowanego, czyli

$$\begin{cases} \phi_t = \eta\phi_{xx} + \hat{A}\psi + \hat{\rho}\phi \\ \psi_t = \psi_{xx} - \frac{2\hat{\rho}}{\hat{A}}\phi_{xx} - \hat{\rho}\phi - \hat{A}\psi \\ \frac{\partial\phi}{\partial x} = 0, \quad \frac{\partial\psi}{\partial x} = 0, \quad x \in \{0,1\} \\ \phi(x,0) = A_0 - \hat{A}, \quad \psi(x,0) = \rho_0 - \hat{\rho}. \end{cases} \tag{14}$$

Twierdzenie 5.1. *Przy założeniu $\eta(\hat{A} + \pi^2 k^2) - 3\hat{\rho} < 0$ dla pewnego $k = 1, 2, 3 \ldots$, gdzie $(\hat{A}, \hat{\rho})$ jest stanem stacjonarnym układu 3, rozwiązanie $(0,0)$ układu 14 jest niestabilne.*

Aby pokazać powyższe twierdzenie, użyjemy następujących lematów

Lemat 5.2. *Dla macierzy M_{2x2}, jeżeli tr(M)<0 to istnieje co najmniej jedna dodatnia wartość własna wtedy i tylko wtedy, gdy det(M)<0.*

Lemat 5.3. *Układ równań różniczkowych, posiadający stan stacjonarny S, jest niestabilny w S, gdy macierz układu w punkcie S posiada co najmniej jedną wartość własną o dodatniej części rzeczywistej.*

Dowód. Wystarczy znaleźć nieograniczone rozwiązanie w postaci

$$\phi(x,t) = \alpha_k(t)W_k(x)$$
$$\psi(x,t) = \beta_k(t)W_k(x),$$

gdzie $W_k(x) = cos(k\pi x)$.

Wstawiamy ϕ, ψ w powyższych postaciach do układu i otrzymujemy

$$\alpha_k'(t) = -\eta\lambda_k\alpha_k(t) + \hat{\rho}\alpha_k(t) + \hat{A}\beta_k(t)$$
$$\beta_k'(t) = -\lambda_k\beta_k(t) + \frac{2\hat{\rho}}{\hat{A}}\lambda_k\alpha_k(t) - \hat{A}\beta_k(t) - \hat{\rho}\alpha_k(t),$$

gdzie $\lambda_k = k^2\pi^2$, i możemy to zapisać w postaci macierzowej jako

$$\begin{pmatrix} \alpha_k'(t) \\ \beta_k'(t) \end{pmatrix} = \begin{pmatrix} -\eta\lambda_k + \hat{\rho} & \hat{A} \\ \frac{2\hat{\rho}}{\hat{A}}\lambda_k - \hat{\rho} & -\lambda_k - \hat{A} \end{pmatrix} \begin{pmatrix} \alpha_k(t) \\ \beta_k(t) \end{pmatrix} \tag{15}$$

Taki układ ma nieograniczone rozwiązanie, gdy istnieje wartość własna macierzy układu ze ściśle dodatnią częścią rzeczywistą. Dla powyższej macierzy układu, oznaczmy ją M, mamy

$$\mathrm{tr}(M) = -\eta\lambda_k + \hat{\rho} - \lambda_k - \hat{A} = -\lambda_k(\eta+1) + \hat{\rho} - \hat{A}$$

oraz

$$\det(M) = -(-\eta\lambda_k + \hat{\rho})(\lambda_k + \hat{A}) - \hat{A}(\frac{2\hat{\rho}}{\hat{A}}\lambda_k - \hat{\rho}) = \eta\lambda_k^2 + \lambda_k(\eta\hat{A} - 3\hat{\rho}).$$

Wprowadzając model zaznaczaliśmy, że $\eta \in (0,1)$ oraz wiemy, że $\lambda_k = k^2\pi^2$ dla $k = 1,2,3\ldots$, zatem $-\lambda_k(\eta+1) \leqslant -\pi^2$. Co więcej, z postaci stanu stacjonarnego, wiemy że $\hat{\rho} \in (0,1)$ oraz $\hat{A} \geqslant 0$, tak więc $\hat{\rho} - \hat{A} \leqslant 1$. Z tych dwóch nierówności wynika naturalnie, że $tr(M) < 0$ dla dowolnych η i k. Korzystając z wcześniejszego

lematu, wiemy, że skoro ślad jest ujemny, to aby istniała wartość własna tej macierzy o dodatniej części rzeczywistej, jej wyznacznik również musi być ujemny., czyli gdy $\eta\lambda_k^2 + \lambda_k(\eta\hat{A} - 3\hat{\rho}) < 0$. Sprowadza się to więc do znalezienia takich parametrów, dla których

$$\eta(\hat{A} + \lambda_k) - 3\hat{\rho} < 0. \tag{16}$$

Możemy zaobserwować zachowanie się powyższej nierówności na wykresie. Niech $\hat{A}$ będzie na osi $0X$, a $\hat{\rho}$ na osi $0Y$, wtedy na poniższych wykresach widać kiedy spełniona jest powyższa nierówność w zależności od zmiany parametrów η i k:

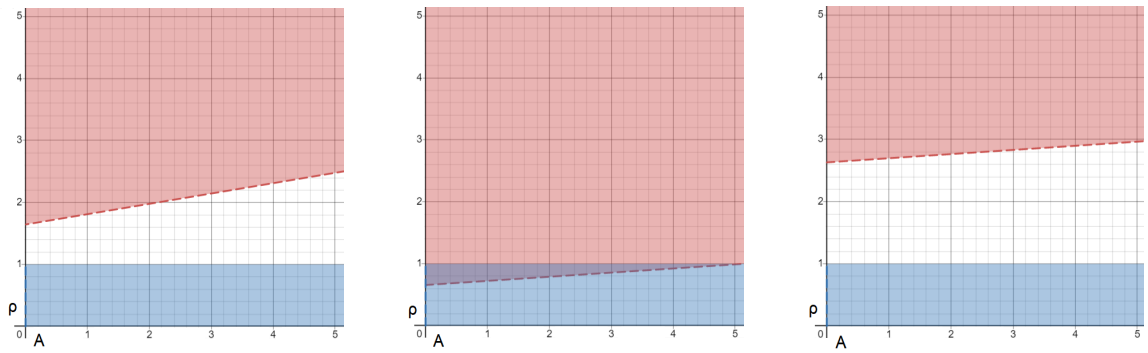

(a) $\eta = 1/2, k = 1$ (b) $\eta = 1/5, k = 1$ (c) $\eta = 1/5, k = 2$

Rysunek 4: Wykresy obrazują, jako pole czerwone, dla jakich wartości stanu $(\hat{A}, \hat{\rho})$ spełniona jest nierówność 16 dla ustalonych wartości η i k. Kolejne wykresy pokazują jak na zmianę tego obszaru wpływa zmiana tych parametrów. Pole niebieskie przypomina, w jakim obszarze znajdują się rzeczywiste wartości $\hat{A}, \hat{\rho})$.

Pole czerwone pokazuje gdzie spełniona jest nierówność, natomiast pole niebieskie oznacza pole, gdzie wartości $\hat{A}, \hat{\rho}$ są rzeczywiste. Poza tym polem nawet bez dyfuzji mieliśmy niestabilność, także aby zaobserwować zmianę stabilności chcemy wiedzieć gdzie pola niebieskie i czerwone się przetną. Łatwo zauważyć, że będzie się to działo, gdy spełniona będzie nierówność $\eta < 3/\pi^2 k^2$. W szczególności możemy wziąć przykładowe dane $\hat{A} = 1, \hat{\rho} = 0.8, \eta = 0.2$ spełniające wyznaczoną nierówność i odpowiednie dla nich rozwiązanie układu będzie nieograniczone.

□

Nieograniczoność rozwiązania (0,0) tego układu liniowego jest jednoznaczna z niestabilnością stanu stacjonarnego $(\hat{A}, \hat{\rho})$ w pełnym modelu z dyfuzją, ponieważ układ zlinearyzowany odpowiada modelowi pełnemu z pewnym zaburzeniem.

6 Symulacje numeryczne modelu

6.1 Na odcinku [0,l]

W niniejszym rozdziale przedstawione są wyniki symulacji numerycznych omawianego modelu na odcinku. Za funkcję χ przyjęty jest logarytm naturalny. Może to w przybliżeniu opisywać zachowanie kryminalistów w niewielkiej miejscowości, gdzie zabudowania skoncentrowane są wzdłuż głównej drogi. W symulacjach odcinek podzielony jest na 100 elementów, co odpowiada niejako rzędowi 100 domów. Jest to uzupełnienie wcześniejszych analiz matematycznych modelu, pozwalające na lepsze zrozumienie jego zachowania. Czerwona przerywana linia na wykresach reprezentuje wartości stanów stacjonarnych dla odpowiednich danych użytych w każdej symulacji. Jeśli nie zostało powiedziane inaczej, symulacje przeprowadzono dla wartości parametrów $\eta = 0.2, A^0 = \frac{1}{30}$ oraz $R = 1.6$, natomiast warunki początkowe są stale równe odpowiednim stanom stacjonarnym, mianowicie $A_0(x) \equiv A^0 + R \approx 1.63$, a $\rho_0(x) \approx \frac{R}{R+A^0} = 0.98$.

6.1.1 Symulacje modelu dla różnych warunków początkowych

Pierwsza symulacja pokazuje, że gdy obie wartości A i ρ zostaną umieszczone początkowo w swoich stanach stacjonarnych, to w nich pozostają.

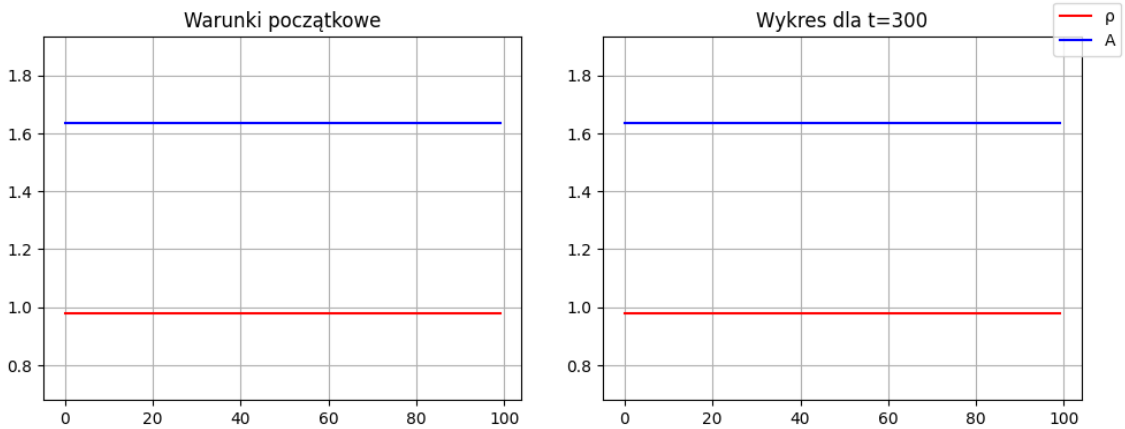

Rysunek 5: Wynik symulacji dla stałych warunków początkowych, równych co do wartości stanom stacjonarnym. Wynik symulacji nie zmienia się w czasie, pozostaje w miejscu warunku początkowego.

Natomiast gdy zaburzymy warunek początkowy ρ szumem białym o wariancji 0.01

i średniej 0, obserwujemy oscylacje wokół stanów stacjonarnych. Nie są one symetryczne wobec stanów stacjonarnych, oscylacje dla ρ są przesunięte w dół w stosunku do stanu stacjonarnego, a oscylacje dla A przesunięte są lekko w górę. Dokładnie analogicznie wygląda sytuacja, gdy takiemu zaburzeniu ulegnie warunek początkowy A.

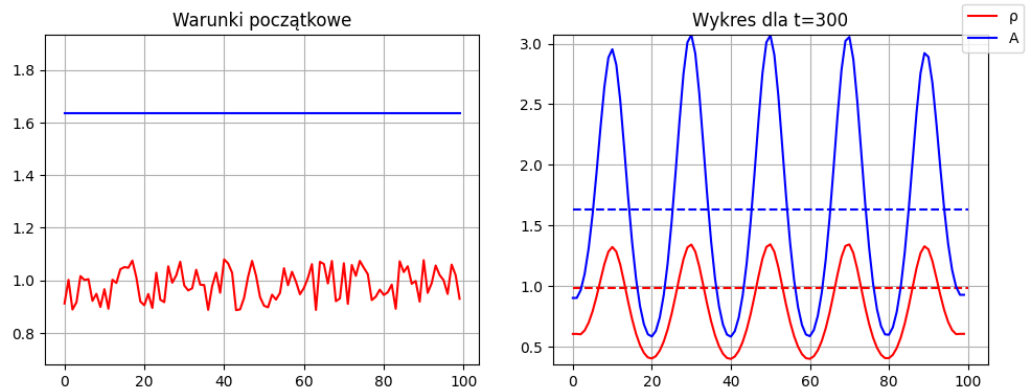

(a) Zaburzony warunek początkowy dla ρ.

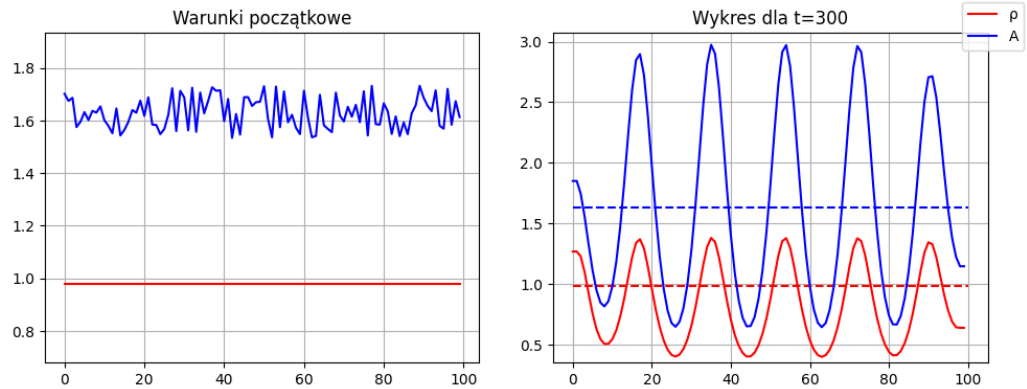

(b) Zaburzony warunek początkowy dla A.

Rysunek 6: Wyniki symulacji modelu, gdy warunki początkowe zostaną zaburzone szumem białym o wariancji 0.1.

Wynik symulacji jest podobny niezależnie od zaburzenia - poniżej zaprezentowany jest ten efekt dla warunku początkowego ρ zaburzonego szumem białym o wariancji 0.001, będącego sinusem o amplitudzie 0.2 oraz będącego funkcją kawałkami prostą. Wyniki prezentowane są jedynie dla zaburzeń stanu początkowego ρ, ale tak samo jak wcześniej, wyniki są analogiczne.

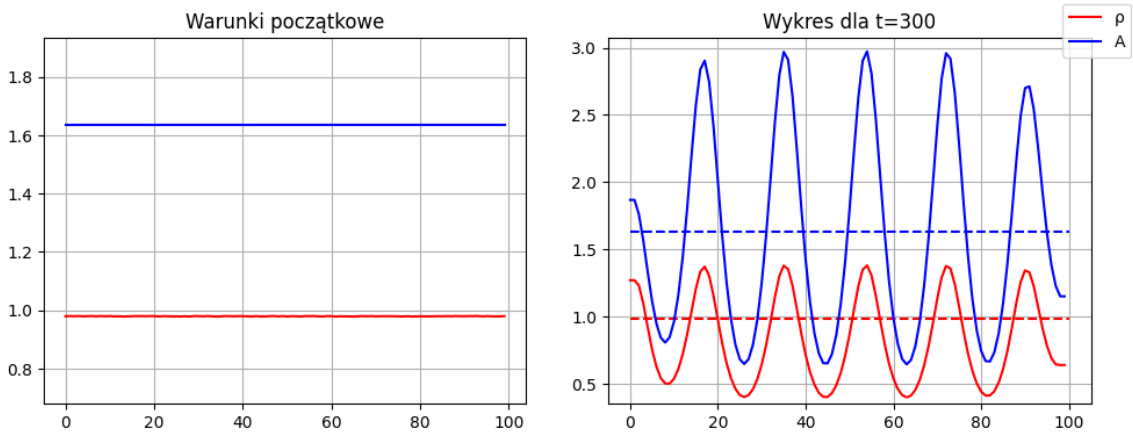

(a) Warunek początkowy ρ zaburzony szumem o wariancji 0.001

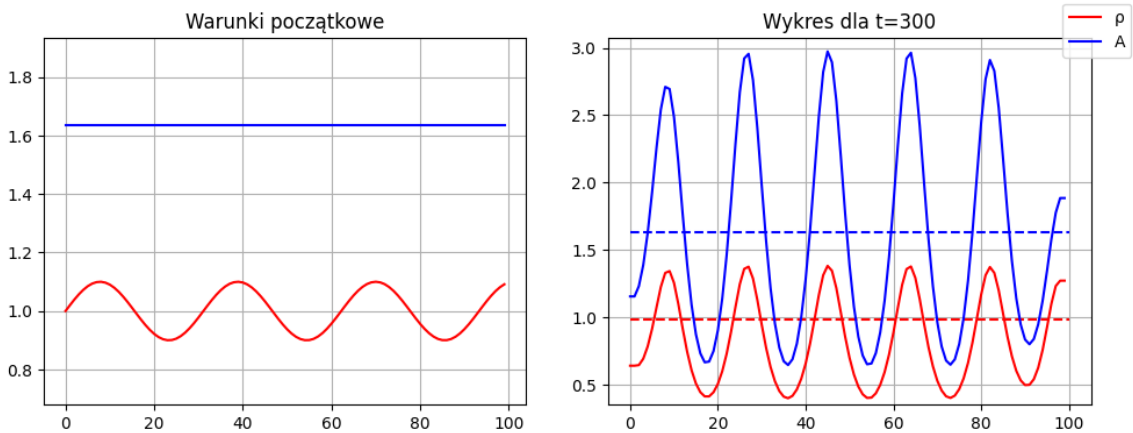

(b) Warunek początkowy ρ będący funkcją sinus, o amplitudzie 0.2 i przesuniętej o 1.

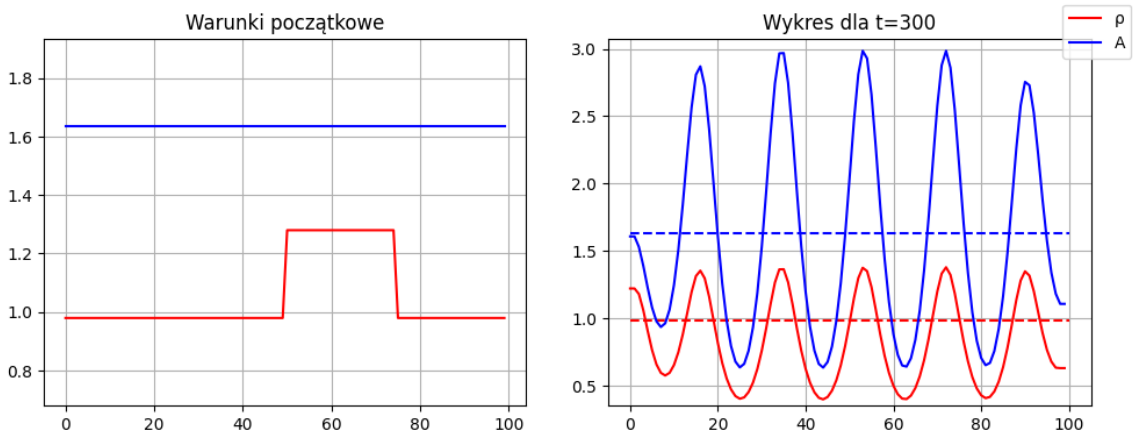

(c) Warunek początkowy ρ przesunięty o 0.3 na 1/4 długości odcinka.

Rysunek 7: Wyniki symulacji modelu dla różnych warunków początkowych ρ.

Powyższe symulacje obrazują występowanie niestabilności Turinga dla wybranych wartości parametrów.

6.1.2 Zmiany parametrów

Poniższe symulacje wizualizują zmianę rozwiązania wraz ze zmianami parametrów η, A^0 i R. Gdy ustawimy warunki początkowe w stanach równowagi zmiany parametrów nie mają wpływu, dlatego zaprezentowane poniżej zostały symulacje dla warunku początkowego ρ zaburzonego szumem białym o wariancji 0.1, pokazanego wcześniej na rysunku (6a).

Najpierw zajmiemy się analizą zmiany rozwiązań w zależności od zmiany wartości η. Przypomnijmy, że parametry A^0 i R wykorzystane w tych symulacjach są równe $\frac{1}{30}$ i 1.6 odpowiednio.

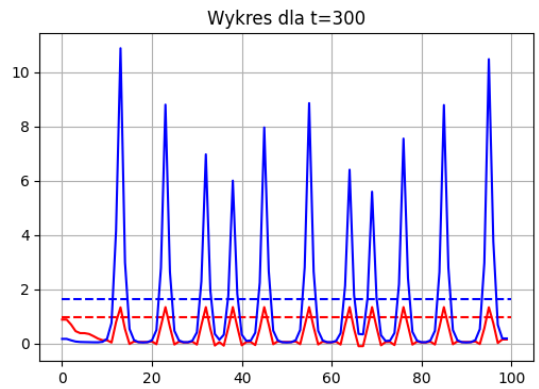

(a) $\eta = 0.01$

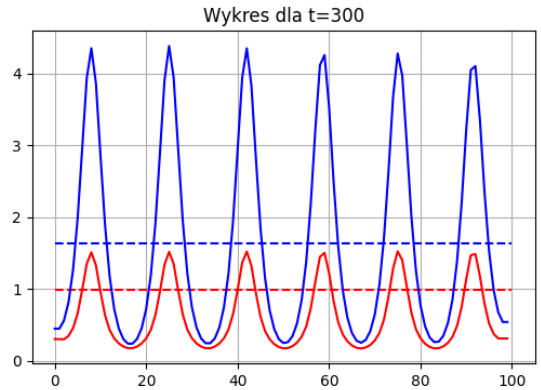

(b) $\eta = 0.1$

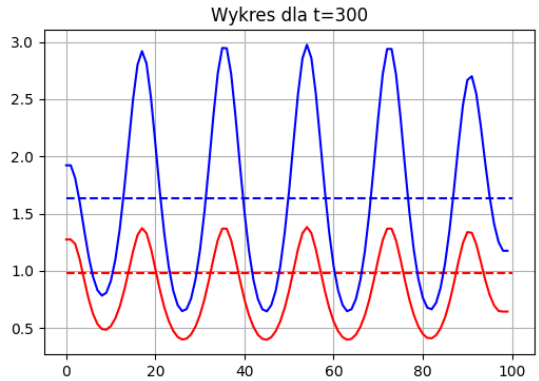

(c) $\eta = 0.02$

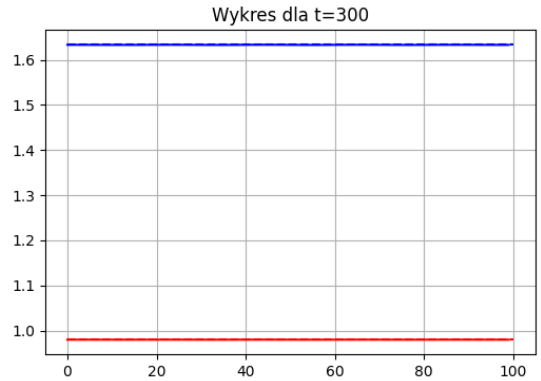

(d) $\eta = 0.03$

Rysunek 8: Wyniki symulacji modelu dla różnych wartości parametru η - im jest większy, tym rozwiązanie jest bliższe stanom stacjonarnym

Największe różnice widać w 2 momentach: między rysunkami (a) i (b) - zmiana kształtu, następuje około momentu $\eta = 0.1$, może być wynikiem niestabilności algorytmu numerycznego; oraz (c) i (d) - wyraźnie wygładzenie na wysokości stanów stacjonarnych, następuje między 0.29 a 0.3.

Kolejnym parametrem, którego wpływ możemy obserwować, jest A^0.

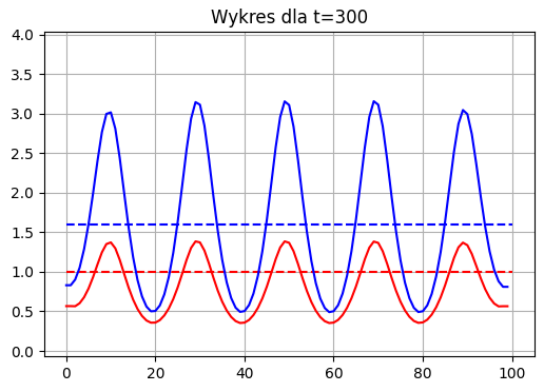

(a) $A^0 = 0$

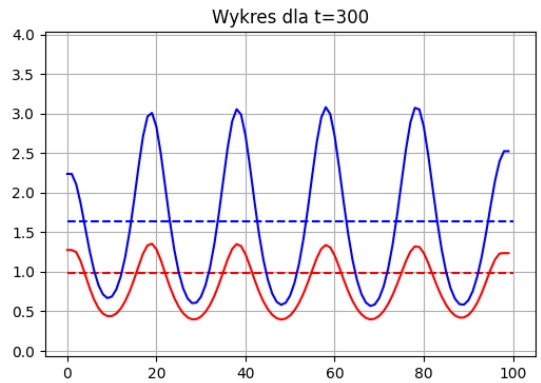

(b) $A^0 = 1/30$

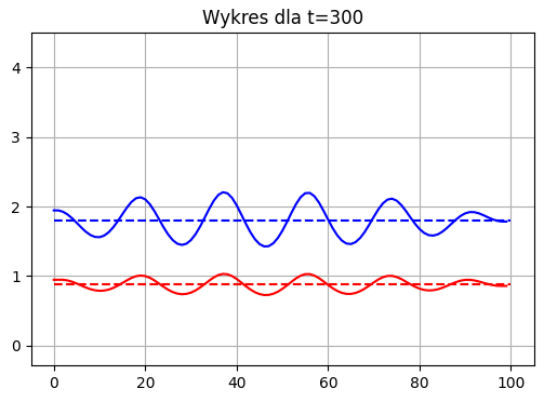

(c) $A^0 = 1/5$

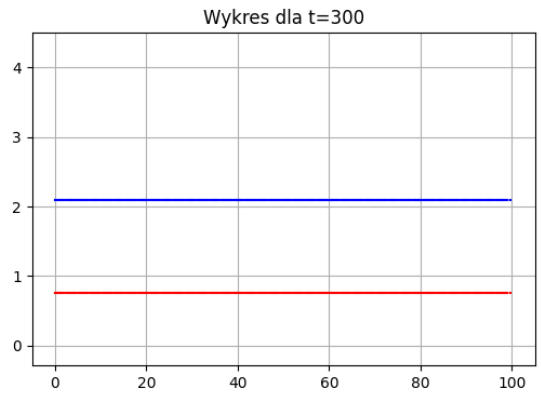

(d) $A^0 = 1/2$

Rysunek 9: Wyniki symulacji modelu dla różnych wartości parametru A^0 - im jest większy, tym rozwiązanie jest bliższe stanom stacjonarnym.

Obserwujemy, że im większe A^0, tym gładsze rozwiązanie. Nagłe wyraźne wygładzenie na poziomie stanów stacjonarnych następuje w okolicy $A^0 = 0.22$. Naturalnie również wraz ze zmianą A^0 zmianie ulegają również wartości stanów stacjonarnych.

Ostatnim parametrem jest R, również wpływające na stany stacjonarne. Zachowanie rozwiązania w zależności od niego przedstawione jest poniżej.

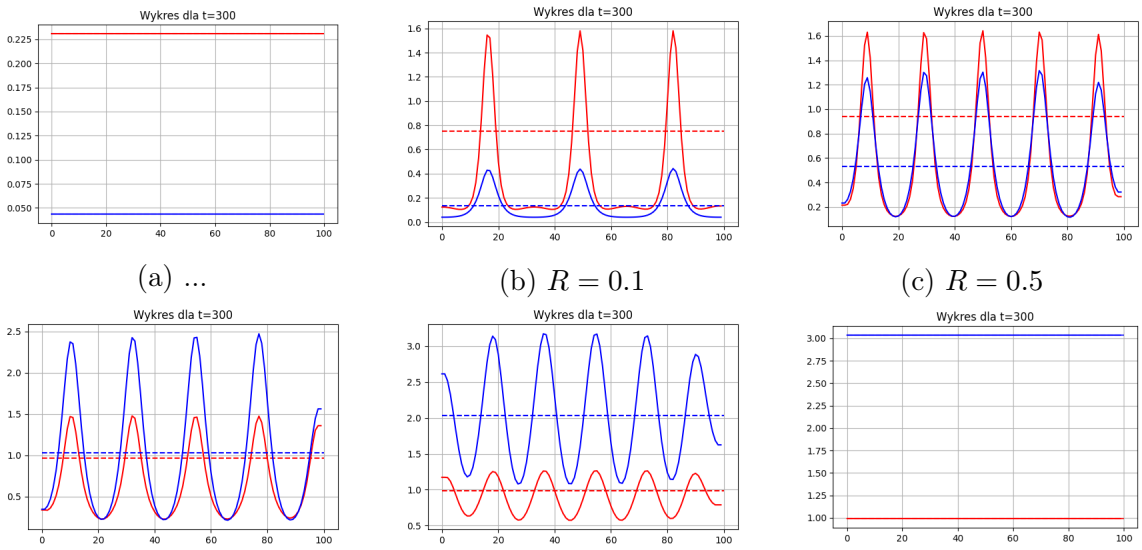

(a) ... (b) $R = 0.1$ (c) $R = 0.5$

(d) $R = 1$ (e) $R = 2$ (f) $R = 3$

Rysunek 10: Wyniki symulacji modelu w zależności od zmiany parametru R.

W tym przypadku również następuje nagłe wygładzenie w dwóch momentach - gdy idziemy z parametrem R poniżej ok. 0.02 oraz powyżej ok. 2.41

6.2 Na kwadracie $[0, l] \times [0, l]$

W tej części rozdziału zaprezentowanych jest kilka wizualizacji zachowania naszego modelu w przestrzeni $\mathbb{R}^2$. Dla tych symulacji również warunkiem początkowym branym głównie pod uwagę jest stałe A_0 oraz ρ_0 zaburzone szumem białym o wariancji 0.1, widoczny jest on na rysunku 11.

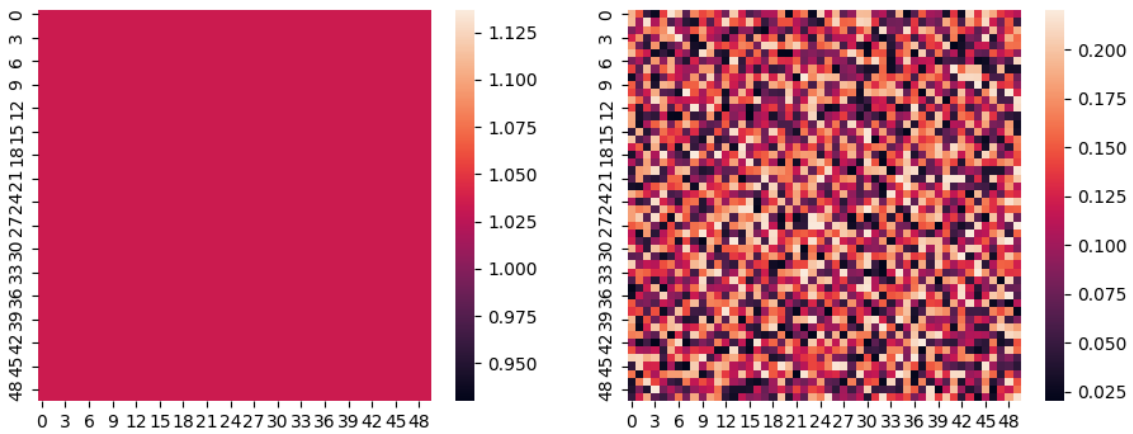

Rysunek 11: Warunki początkowe, od lewej dla A oraz ρ.

Jako bazowe ustawiono parametry $\eta = 0.1, A^0 = 1/30, R = 0.5$, jeśli nie wyszczególniono zmiany parametru dla konkretnej symulacji, ma on wartość bazową. Poniżej zaprezentowana jest zmiana w czasie rozwiązań dla tych bazowych parametrów.

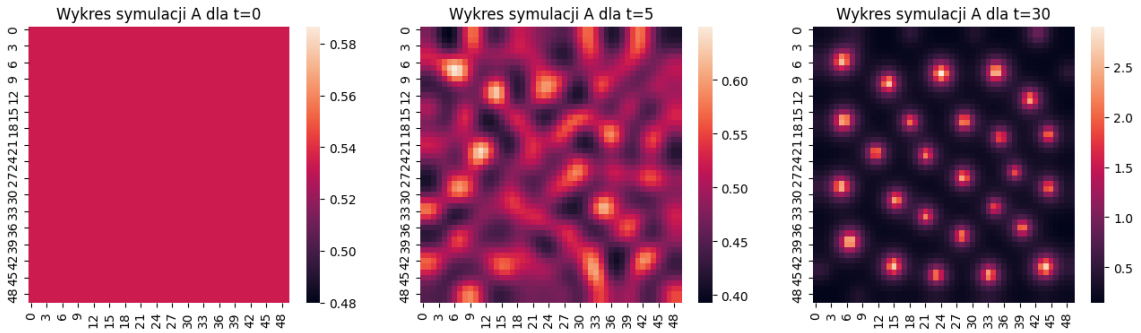

(a) Zachowanie w czasie A.

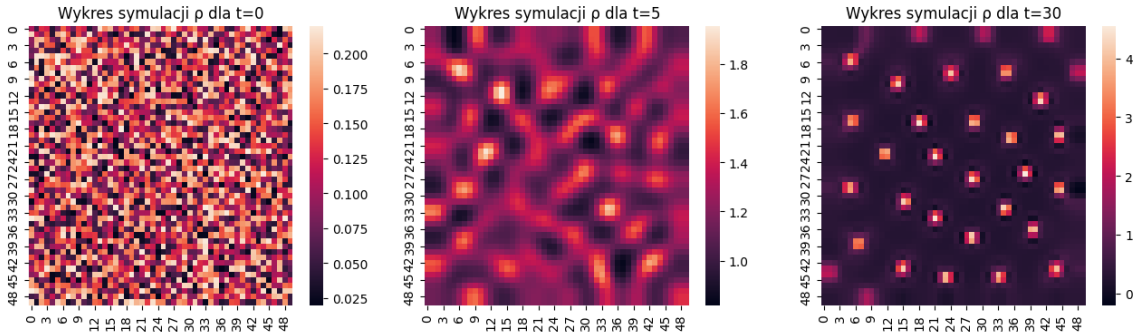

(b) Zachowanie w czasie ρ.

Rysunek 12: Kolejne etapy symulacji modelu dla wartości bazowych $\eta = 0.1, A^0 = 1/30, R = 0.5$.

Manewrując wartościami parametrów, możemy zauważyć, że im większa wartość R tym zagęszczenia na wykresie są gęstsze, natomiast ich rozmiar zmienia się proporjonalnie do zmiany wartoście η. Zmiana parametru A^0 nie jest wyraźnie zauważalna.

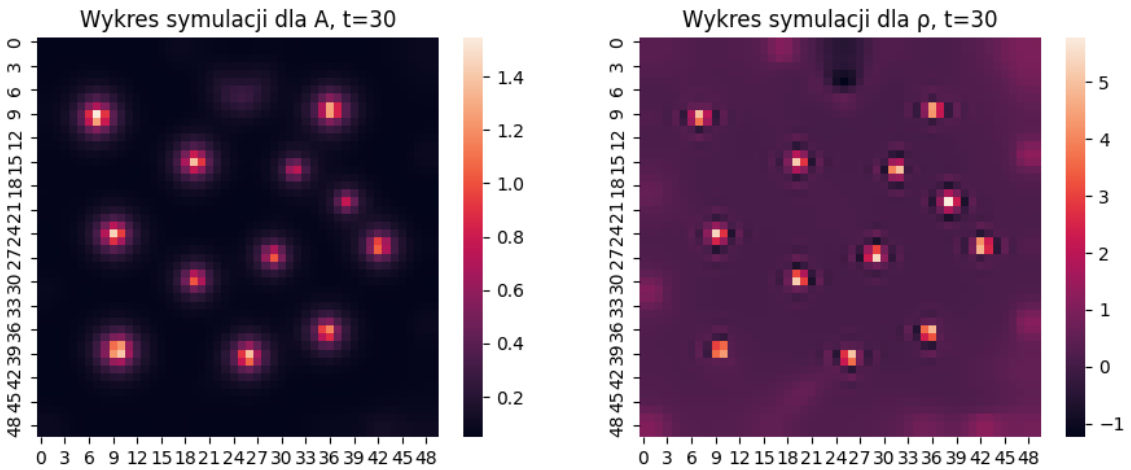

(a) $R = 0.1$

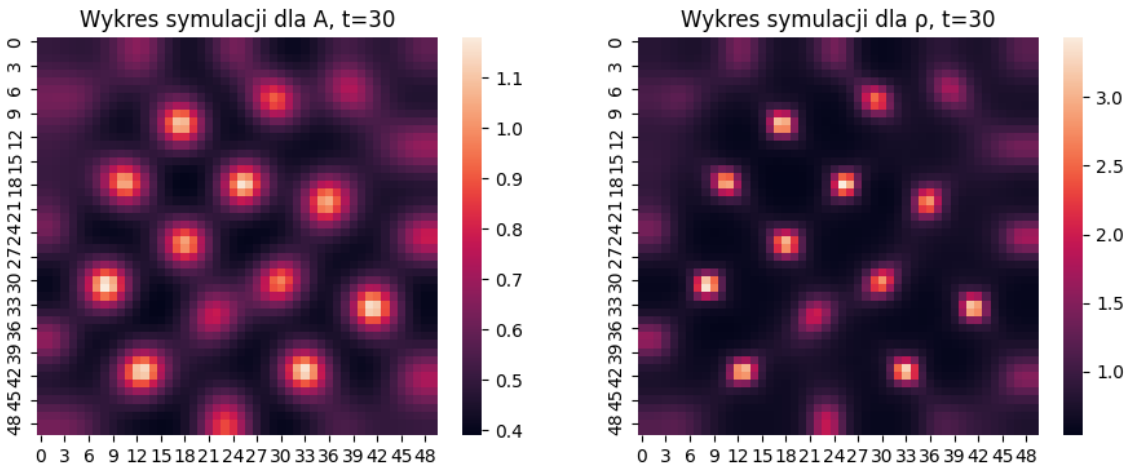

(b) $\eta = 0.2$

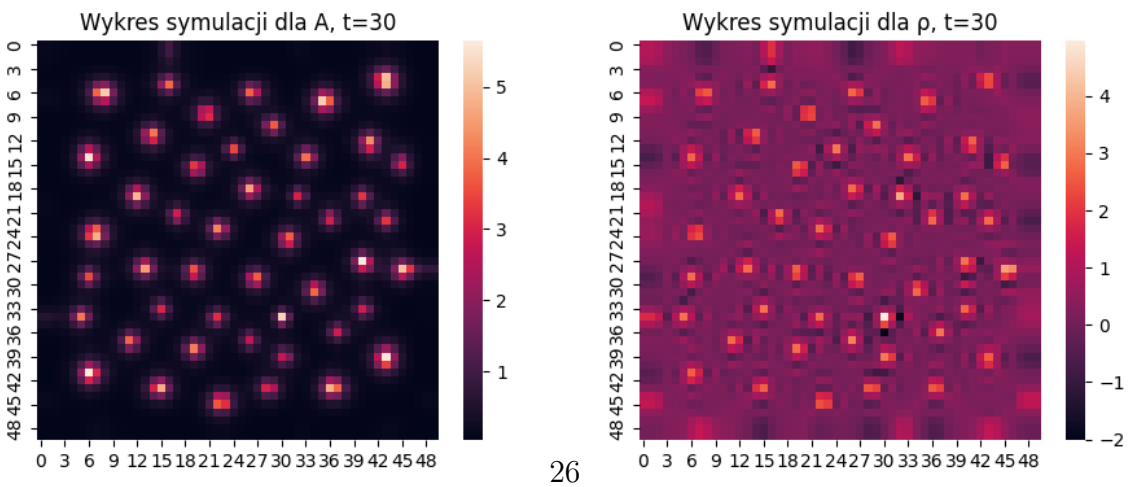

(c) $\eta = 0.03$

Rysunek 13: Wyniki symulacji dla zmiany pojedynczego parametru: (a) zmniejszenie R; (b) zwiększenie η; (c) zmniejszenie η.

Poniżej przedstawiono dodatkowe ciekawe wyniki symulacji przy zmianie warunku początkowego ρ na kawałkami stały,a także zmiany dwóch parametrów jednocześnie (przy poprzednim warunku początkowym).

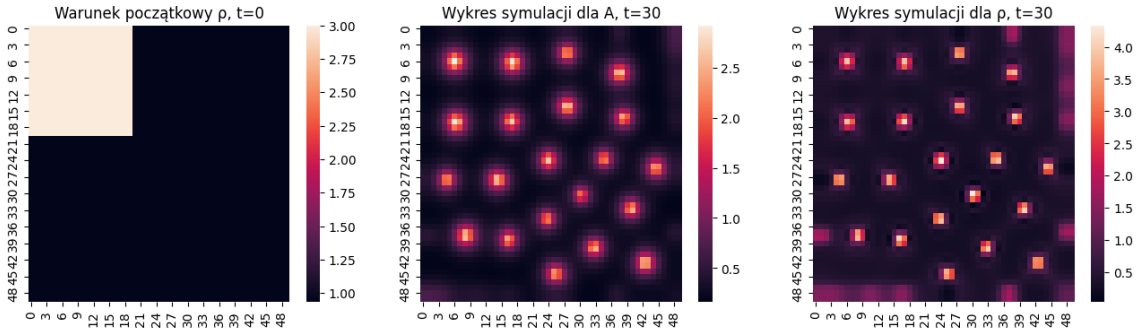

Rysunek 14: Warunek brzegowy ρ_0 stale równy 0 poza lewym górnym rogiem, gdzie wartość podniesiona jest do 3.

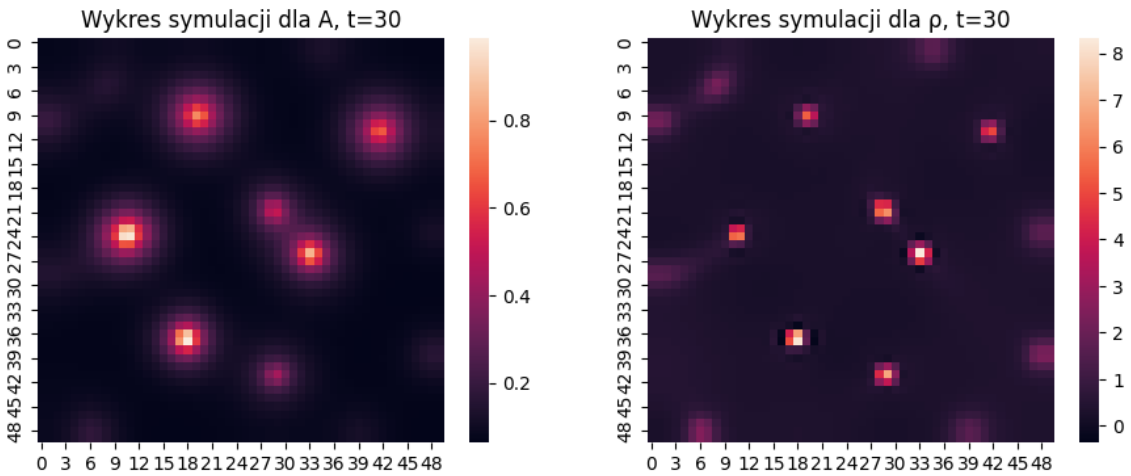

(a) $\eta = 0.25, R = 0.1$

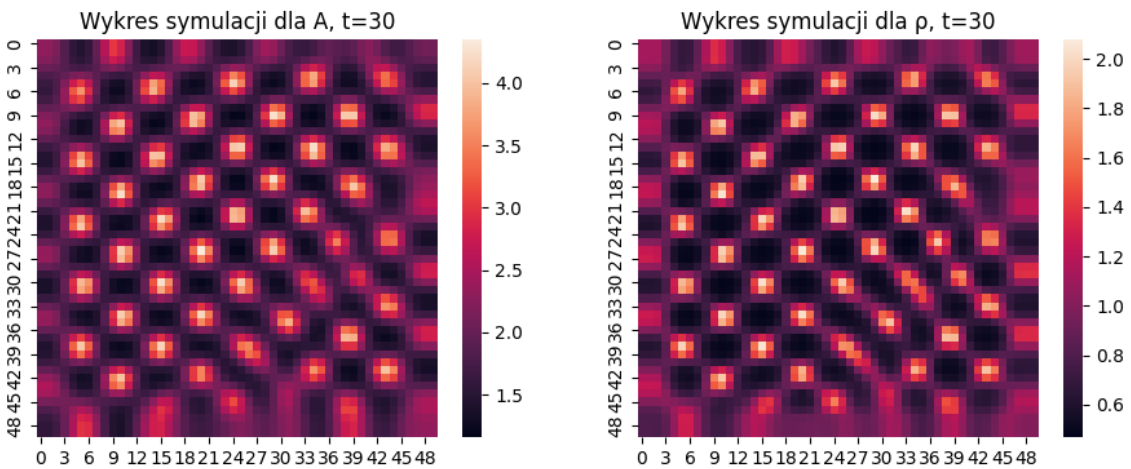

(b) $\eta = 0.05, R = 2$

Rysunek 15: Wyniki symulacji dla zmiany parametrów: (a) η na większy i R na mniejszy; (b) η na mniejszy i R na większy.

7 Dodatek programistyczny

Poniżej znajduje się autorski kod użyty do wygenerowania symulacji numerycznych w powyższej pracy. Kod został napisany w języku programowania *Python*, głównie z użyciem biblioteki *numpy*:

```python
import pandas
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.animation as animation
import math
import tqdm
import seaborn as sns

def gradient(u, dx=1):
    res = u[2:]-u[:-2]
    return res/(2*dx)

def laplasjan(u, dx=1):
    dif = u[2:]+u[:-2]-2*u[1:-1]
    return dif/(dx**2)

dx = 1/5
dt = 1/100
l = 5*20
T = 300
eta = 0.27
A0 = 1/30
B = 1.6
A_0 = np.ones(l)*(A0+B)
ro_0 = np.ones(l)*ro0
eps = 0.1
ro_0 = np.maximum(eps*(2*np.random.random(l) - 1) + 0.1,0)

def symulacja(dx,dt,l,T,eta,A0,B,A_0,ro_0,t):
    time = int(T/dt)
    A = np.zeros((l,time))
    ro = np.zeros((l,time))
    A[:,0] = A_0
    ro[:,0] = ro_0
    for i in tqdm.tqdm(range(1, time)):
        # pierwsze rownanie z modelu
        A_next = eta * laplasjan(A[:,i-1],dx) - A[1:-1,i-1] + np.multiply(A[1:-1,i-1],ro[1:-1,i-1]) + A0
        A_next = A[1:-1,i-1] + dt*A_next
        A_next = np.append(A_next[0],np.append(A_next,A_next[-1]))
        A[:,i] = A_next
        # drugie rownanie z modelu
        A_log = np.log(np.maximum(A[:,i-1],0.01))
        ro_grad_A = np.multiply(ro[1:-1,i-1],gradient(A_log,dx))
        ro_grad_A = np.append(ro_grad_A[0],np.append(ro_grad_A,ro_grad_A[-1]))
        ro_next = 1*laplasjan(ro[:,i-1],dx) - 2*1*gradient(ro_grad_A,dx) + B - np.multiply(A[1:-1,i-1], ro[1:-1,i-1])
        ro_next = ro[1:-1,i-1] + dt*ro_next
        ro_next = np.append(ro_next[0],np.append(ro_next,ro_next[-1]))
        ro[:,i] = ro_next
    return A, ro

# 2D
dx = 1/5
dt = 1/100
l = 50
T = 30
eta = 0.1
A0 = 1/30
R = 0.16
A_0 = np.ones((l,l))*(A0+R)
eps = 0.1
ro_0 = np.maximum(eps*(2*np.random.random((l,l)) - 1) + 0.1,0)

def sym2d(dx,dt,l,T,eta,A0,R,A_0,ro_0):
    time = int(T/dt)
    A = np.zeros((l,l,time))
    ro = np.zeros((l,l,time))
    A[:,:,0] = A_0
    ro[:,:,0] = ro_0

    for i in tqdm.tqdm(range(1, time)):
        # pierwsze rownanie z modelu
        A_next_2d = eta*laplasjan_2d(A[:,:,i-1],dx)-A[1:-1,1:-1,i-1]+np.multiply(A[1:-1,1:-1,i-1],ro[1:-1,1:-1,i-1])+A0
        A_next_2d = A[1:-1,1:-1,i-1] + dt*A_next_2d
        A_next_2d = np.concatenate((A_next_2d[0,:].reshape(1,-1),A_next_2d,A_next_2d[-1,:].reshape(1,-1)))
```

```
        A_next_2d = np.hstack((A_next_2d[:,0].reshape(A_next_2d.shape[0],1),A_next_2d,A_next_2d[:,-1].reshape(A_next_2d.shape[0],1)))
        A[:,:,i] = A_next_2d
        # drugie rownanie z modelu
        grad_ro = gradient_2d(ro[:,:,i-1])
        grad_logA = gradient_2d(np.log(np.maximum(A[:,:,i-1],0.01)))
        ro_temp_x = 2*(grad_logA[0,:,:]*ro[1:-1,1:-1,i-1])
        ro_temp_y = 2*(grad_logA[1,:,:]*ro[1:-1,1:-1,i-1])
        gr_x = ro_temp_x[1:-1,2:]-ro_temp_x[1:-1,:-2]
        gr_y = ro_temp_y[2:,1:-1]-ro_temp_y[:-2,1:-1]
        gr_sum = gr_x+gr_y
        gr_sum = np.concatenate((gr_sum[0,:].reshape(1,-1),gr_sum,gr_sum[-1,:].reshape(1,-1)))
        gr_sum = np.hstack((gr_sum[:,0].reshape(gr_sum.shape[0],1),gr_sum,gr_sum[:,-1].reshape(gr_sum.shape[0],1)))
        ro_next_2d = laplasjan_2d(ro[:,:,i-1]) + R
        ro_next_2d = ro_next_2d - np.multiply(A[1:-1,1:-1,i-1],ro[1:-1,1:-1,i-1])
        ro_next_2d = ro_next_2d - 2*(gr_sum)
        ro_next_2d = ro[1:-1,1:-1,i-1] + dt*ro_next_2d
        ro_next_2d = np.concatenate((ro_next_2d[0,:].reshape(1,-1),ro_next_2d,ro_next_2d[-1,:].reshape(1,-1)))
        ro_next_2d = np.hstack((ro_next_2d[:,0].reshape(ro_next_2d.shape[0],1),ro_next_2d,ro_next_2d[:,-1].reshape(ro_next_2d.shape[0],1)))
        ro[:,:,i] = ro_next_2d

    return A, ro
```

Bibliografia

[1] Chaohao Pan i in. "Crime modeling with truncated Lévy flights for residential burglary models". English. W: *Math. Models Methods Appl. Sci.* 28.9 (2018), s. 1857–1880. ISSN: 0218-2025. DOI: 10.1142/S0218202518400080.

[2] Benoit Perthame. *Parabolic Equations in Biology. Growth, Reaction, Movement and Diffusion*. Springer, 2015. ISBN: 978-3-319-19499-8.

[3] M. B. Short, A. L. Bertozzi i P. J. Brantingham. "Nonlinear patterns in urban crime: hotspots, bifurcations, and suppression". English. W: *SIAM J. Appl. Dyn. Syst.* 9.2 (2010), s. 462–483. ISSN: 1536-0040. DOI: 10.1137/090759069.

[4] M. B. Short i in. "A statistical model of criminal behavior". English. W: *Math. Models Methods Appl. Sci.* 18 (2008), s. 1249–1267. ISSN: 0218-2025. DOI: 10.1142/S0218202508003029.